

3.1 บทที่ 1: Understanding Big Data



Understanding Big Data

8 - 9 กันยายน 2563

ผศ.ดร.สิริกร สันติโรจนกุล

อาจารย์ภูษิต ก้อนสุรินทร์

อาจารย์ ดร.เอกสิทธิ์ เทียมแก้ว

Digital Marketing Solution Providers Center

เพจ @digitalSPC




Understanding Big Data


- Big Data Concepts and Terminology
- Characteristics of Big Data
- Types of Data
- Big Data Ecosystem
- Big Data for Organization Data Disruption
- Storing Big Data
- Extract Transform Load (ETL)

Big Data ?

- Big Data = การใช้ประโยชน์จากกระบวนการรวบรวม การจัดเก็บ การประมวลผล และการวิเคราะห์ข้อมูล ที่มีความหลากหลาย มีปริมาณมหาศาล และสามารถใช้งานได้อย่างรวดเร็ว




Why Big Data ?



Big Data Terminology

- **Datasets** : ชุดข้อมูลหรือกลุ่มข้อมูลที่เกี่ยวข้งกัน ซึ่งอาจจะอยู่ในหลากหลายรูปแบบ เช่น ไฟล์ข้อมูล รูปภาพ ตารางข้อมูล เป็นต้น



Sources of Open Datasets

30

- UCI Machine Learning Repository!

<http://archive.ics.uci.edu/ml/index.php>

- World Bank Open Data

<https://data.worldbank.org/>

- Kaggle Open Datasets and Machine Learning Projects

<https://www.kaggle.com/datasets>

- UNICEF Dataset

<https://data.unicef.org/>

- Google Public Data Explorer


<https://www.google.com/publicdata/directory>

- Google Dataset Search


<https://datasetsearch.research.google.com/>

- Open Data Thailand

<https://data.go.th/>



<https://data.go.th/>



The screenshot shows the homepage of the data.go.th website. At the top, there is a navigation bar with icons for Home, Data, Organizations, Data Groups, Programs and News, Documents, and Data Request. Below this, there is a language selector showing Thai and English flags, and a unit selector (ก, ก, ก). The main heading is "กลุ่มชุดข้อมูล" (Data Groups). Below this is a search bar with the placeholder text "ค้นหาหมวดหมู่..." and a magnifying glass icon. To the right of the search bar, it says "พบ 15 หมวดหมู่" (Found 15 categories). Below the search bar, there is a grid of 12 data categories, each with an icon and a count in parentheses:

- ศาสนา ศิลปะ และวัฒนธรรม (140)
- กฎหมาย ศาล และอาชญากรรม (79)
- การศึกษา (26)
- เศรษฐกิจ การเงิน และอุตสาหกรรม (284)
- สาธารณสุข (85)
- เกษตรกรรม (75)
- สถิติทางการ (469)
- วิทยาศาสตร์ เทคโนโลยี ดิจิทัล และนวัตกรรม (63)
- เมืองและภูมิภาค (172)
- สังคมและสวัสดิการ (260)
- คมนาคมและโลจิสติกส์ (242)
- การท่องเที่ยวและกีฬา (49)

Big Data Terminology

32

Data Cleansing : คือกระบวนการในการ



C	D	E	F	G	H	I	J	K	L	M
เลิกเพื่อป้อนหรือเลือกซื้อสินค้า	ชื่อนี้อย่าลบนะคะ	Lot #1				Lot #2				
ชื่อสินค้า	แบรนด์	รับ	ขาย	ทดสอบ	รวมจ่าย	รับ	ขาย	ทดสอบ	รวมจ่าย	รับ
างกุ้งขอส้มขะสาม	อำพัน	4			0				0	
อยจ้อกรเชียงปู	ออร์แกนิกฟาร์ม	6			0				0	
โด้ถึงเจ้าสีทอง	เบ๊ ภัทตาการ	1			0				0	
ลเบอร์รี่	CMU CORDYCEPS	8			0				0	
ลเบอร์รี่แห้งจัดจาด	#N/A	2			0				0	
กหม่อนหิ	#N/A	1			0				0	
unsack	#N/A	1			0	1			0	
ปประสทอดกรอบ	#N/A	3			0				0	
ะสามแฮมแบบกระปุก	#N/A	8			0				0	
นมเบียร์ทุเรียน พูเล็ก (size S)	นางสาวทุเรียน	2			0				0	
ะสามแฮมมอบแห้งซองใหญ่	#N/A	2			0				0	
ะสามแฮมมอบแห้งซองใหญ่ลายไทย	#N/A	2			0				0	

Data Cleansing

ข้อมูลเป็นแบบนี้จะทำอย่างไรให้ข้อมูลถูกต้อง

อยู่ในรูปแบบเดียวกัน

นำไปใช้วิเคราะห์ได้ และเชื่อถือได้ ?

	A	B	D	E	F	G	H	I
1	วันที่	รายการสินค้า	จำนวน	ราคาขาย	รวมรายได้	ราคาส่ง	ต้นทุน	กำไร
2	3/4/2562	นมดื่มเกษตรมช.	20	20.00	400.00	22.00	440.00	-40.00
3	3/4/2562	ข้าวแช่คว (ซอง)	3	15.00	45.00	15.00	45.00	0.00
4	3/4/2562	ถั่วมิกส์นัท (กระป๋อง)	3	15.00	45.00	15.00	45.00	0.00
5	3/4/2562	ถั่วลายเสือคว (กระป๋อง)	1	63.00	63.00	63.00	63.00	0.00
6	4/4/2562	ถั่วมิกส์นัท (ซอง)	1	15.00	15.00	15.00	15.00	0.00
7	4/4/2562	ข้าวแช่คว (กระป๋อง)	1	59.00	59.00	59.00	59.00	0.00
8	4/4/2562	ข้าวแช่คว (ซอง)	3	15.00	45.00	15.00	45.00	0.00
9	4/4/2562	ถั่วมิกส์นัท (กระป๋อง)	1	75.00	75.00	75.00	75.00	0.00
10	4/4/2562	นมดื่มเกษตรมช.	20	20.00	400.00	18.00	360.00	40.00
11	4/4/2562	ถั่วลายเสือคว (กระป๋อง)	1	63.00	63.00	59.00	59.00	4.00
12	4/4/2562	ถั่วเหลืองคว (กระป๋อง)	1	57.00	57.00	57.00	57.00	0.00
13	5/4/2562	ถั่วมิกส์นัท (ซอง)	2	15.00	30.00	15.00	30.00	0.00
14	5/4/2562	ข้าวแช่คว (ซอง)	1	15.00	15.00	15.00	15.00	0.00
15	5/4/2562	ข้าวแช่คว (ซอง)	1	15.00	15.00	15.00	15.00	0.00

แบรนด์	จังหวัด
นมดื่มเกษตรมช.	เชียงใหม่
ถั่วคุณลุง	แม่ฮ่องสอน
ถั่วคุณลุง	MHS
ถั่วคุณลุง	แม่ฮ่องสอน
ถั่วคุณลุง	แม่ฮ่องสอน
ถั่วคุณลุง	แม่ฮ่องสอน
ถั่วคุณลุง	แม่ฮ่องสอน
ถั่วคุณลุง	มฮส.
นมดื่มเกษตรมช.	ชม.

Garbage in Garbage out
หากไม่ทำ Cleansing

Big Data Terminology

- **Data Analysis** หรือการวิเคราะห์ข้อมูล เป็นกระบวนการตรวจสอบข้อมูลเพื่อค้นหาข้อเท็จจริงความสัมพันธ์รูปแบบข้อมูลเชิงลึกและ/หรือแนวโน้ม
- เป้าหมายโดยรวมของคือเพื่อใช้ในการสนับสนุนการตัดสินใจได้ดีขึ้น


ตัวอย่าง เช่น

- “การวิเคราะห์ข้อมูลการขายไอศกรีมเพื่อดูว่าจำนวนไอศกรีมที่ขายมีความสัมพันธ์กับอุณหภูมิประจำวันอย่างไร”
- ผลของการวิเคราะห์ดังกล่าวจะใช้สนับสนุนการตัดสินใจเกี่ยวกับปริมาณไอศกรีมที่ร้านค้าควรสต็อกไว้โดยสัมพันธ์กับข้อมูลพยากรณ์อากาศ

Big Data Terminology

- **Data Analytics** : การวิเคราะห์ข้อมูลมีความหมายที่กว้างขึ้นซึ่งครอบคลุมถึงการวิเคราะห์ข้อมูล
- การวิเคราะห์ข้อมูลเป็นระเบียบวิธีที่รวมถึงการจัดการวงจรชีวิตของข้อมูลที่สมบูรณ์ซึ่งรวมถึงการรวบรวมทำความสะอาดจัดระเบียบจัดเก็บวิเคราะห์และควบคุมข้อมูล


Big Data Terminology




Big Data Terminology

- **Descriptive Analytics : “What happened ?”**
- การวิเคราะห์เชิงพรรณนาเป็นรูปแบบการใช้ข้อมูลแบบพื้นฐาน โดยเน้นการอธิบายการเกิดเหตุการณ์ต่าง ๆ ในอดีต
- เช่น รายงานธุรกิจ รายงานด้านการทำโฆษณา หรือรายงานผลดำเนินงานที่ผ่านมา เป็นข้อมูลพื้นฐานที่แสดงผลในการทำกิจกรรมต่าง ๆ

Descriptive Analytics case study




Descriptive Analytics Operational



Big Data Terminology


- **Diagnostic Analytics : “Why it happened ?”**
- เป็นการวิเคราะห์เชิงวินิจฉัยหาสาเหตุ โดยเปรียบเทียบข้อมูลในอดีตเทียบกับข้อมูลอื่นเพื่อตอบคำถามว่า ทำไมบางสิ่งเกิดขึ้น
- การวิเคราะห์เชิงวินิจฉัยทำให้มีความเป็นไปได้ที่จะเจาะลึกค้นหา การอ้างอิงและระบุรูปแบบ จากข้อมูลเชิงลึกเกี่ยวกับปัญหาเฉพาะ แต่จะต้องมีข้อมูลที่มีความละเอียดมากเพียงพอ

Diagnostic Analytics Example



Diagnostic Analytics Operational

42




Big Data Terminology

- **Predictive Analytics : “What might happen ?”**
- เป็นการวิเคราะห์เชิงพยากรณ์ รูปแบบการใช้ข้อมูลที่มีความซับซ้อน โดยเป็นการ “พยากรณ์” หรือ “ทำนาย” สิ่งที่กำลังเกิดขึ้น โดยใช้ข้อมูลในอดีต ร่วมกับโมเดลทางคณิตศาสตร์ต่าง ๆ ร่วมกับการทำ Data Mining
- นอกจากนี้ยังทำให้เราสามารถวิเคราะห์หาโอกาสและความเสี่ยงต่าง ๆ ที่จะเกิดขึ้นในอนาคตได้ด้วย เช่น
 - การรู้แนวโน้มทางการตลาด
 - การพยากรณ์ยอดขายหรือการทำโฆษณาว่าจะมีคนร่วมเท่าไร หรือ
 - มีค่า ROI (Return of Investment) เท่าไร


Predictive Analytics Example

Day #	Forecast	Temperature	Humidity	Play outside
Day 1	sunny	hot	high	yes
Day 2	sunny	hot	high	yes
Day 3	cloudy	hot	high	no
Day 4	rainy	mild	high	no
Day 5	rainy	cool	normal	no
Day 6	rainy	cool	normal	no
Day 7	cloudy	cool	normal	yes
Day 8	sunny	mild	high	yes
Day 9	sunny	cool	normal	no
Day 10	rainy	mild	normal	no
Day 11	sunny	mild	normal	yes
Day 12	cloudy	mild	high	no
Day 13	cloudy	hot	normal	yes
Day 14	rainy	mild	high	no




<https://www.analyticsinhr.com/blog/predictive-analytics-human-resources/>

Predictive Analytics Example




Predictive Analytics Operational




Big Data Terminology

- **Prescriptive Analytics : “What should we do?”**
- เป็นการวิเคราะห์เชิงพยากรณ์และทางเลือก เป็นรูปแบบที่มีความซับซ้อนและยากที่สุด
- เพราะไม่เพียงพยากรณ์หรือทำนายว่าอะไรจะเกิดขึ้น แต่ยังให้คำแนะนำในทางเลือกต่าง ๆ และผลแต่ละทางเลือกกว่าจะมี Pros & Consอย่างไร
- โมเดลสามารถปรับเปลี่ยนได้ตามข้อมูลที่เพิ่มเติมเข้ามา ในรูปแบบนี้ยังเป็นการใช้ข้อมูลที่มากที่สุด และเกี่ยวข้องกับเรื่อง Big Data มากที่สุด

Prescriptive Analytics Example



Prescriptive Analytics Operational



Descriptive Analytics

What happened?

Univariate Analysis

Diagnostic Analytics

Why it happened?

Multivariate and Multidimensional

Predictive Analytics

What might happen?

Data mining and Machine learning

Prescriptive Analytics


What should we do?

Optimization

50


Big Data Terminology

- Business Intelligence (BI)
- เป็นกระบวนการที่องค์กรจะใช้ขับเคลื่อนการดำเนินงานด้วยเทคโนโลยี โดยเน้นในด้านการวิเคราะห์ข้อมูลและนำเสนอข้อมูล
- สามารถนำไปช่วยให้ผู้บริหาร ผู้จัดการและผู้ใช้ใน ขององค์กรสามารถ ตัดสินใจทางธุรกิจได้อย่างมีข้อมูล




Business Intelligence

SWOT
 S Strengths จุดแข็ง
 W Weaknesses จุดอ่อน
 O Opportunities โอกาส
 T Threats อุปสรรค




องค์ประกอบของ Business Intelligence (BI)



ตย. คุณลักษณะ Big data :Volume


- Netflix มีสมาชิกมากกว่า 86 ล้านคนทั่วโลกสตรีมเนื้อหามากกว่า 125 ล้านชั่วโมงต่อวัน ส่งผลให้คลังข้อมูลมีขนาดมากกว่า 60 Petabyte(PB)

NETFLIX




Characteristics of Big Data

56



Characteristics of Big Data

ปริมาณข้อมูลขนาดใหญ่



ตย. คุณลักษณะ Big data : Velocity

- Google ได้รับการค้นหาจากผู้ใช้ในการค้นหาข้อมูลมากกว่า 63,000 ครั้งต่อวินาทีในแต่ละวัน



ตย. คุณลักษณะ Big data : Variety

- ข้อมูลใน Facebook ประกอบด้วยข้อมูลทั้ง Unstructured และ Structured Data ในโพสต์ต่าง ได้แก่ ข้อความ ตัวเลข รูปภาพ เสียง วิดีโอ ลิงค์ เว็บไซต์ อีเมล เป็นต้น

facebook

Big data : Variety

60

ข้อมูลเที่ยวบิน
เชียงใหม่ – กรุงเทพฯ

Bundled flight

Cheapest flight

Depart on Thu, 15 Oct
CNX 18:10 ✈ **BKK 19:30**
VietJet Air
1h 20m | Direct

Return on Sun, 18 Oct
BKK 19:20 ✈ **CNX 20:40**
VietJet Air
1h 20m | Direct

[See details](#)

We have selected the cheapest flight to give you the best bundle deal, feel free to change timings, airlines, stops and duration for flight.

Hurry! 53% of properties on our site are fully booked!
Rooms in Bangkok are in high demand on your selected dates. Reserve yours now before prices go up.

SORT: **BEST MATCH** BUNDLE SAVINGS LOWEST PRICE FIRST DISTANCE TOP REVIEWED

These properties were selected just for you.

Agoda Preferred Property

Best seller

Jasmine City Hotel
★★★★☆ Sukhumvit, Bangkok - View on map

Exceptional location Convenient city access

Breakfast

Recommended by 93% of guests

AGODASPONSORED Coupon Code AGODASPONSORE...

BUNDLE SAVINGS
฿ 8,637

฿ 15,014
฿ 6,377
Flight + Hotel
Per person • 3 nights

Excellent
7,148 reviews
8.1
8.1 cleanliness

Select Room

Agoda Preferred Property

Agoda EasyCancel

Al Meroz Hotel Bangkok- The Leading Halal Hotel
★★★★★ Ratchada, Bangkok - View on map

Excellent
1,105 reviews
8.6
9.1 cleanliness

ข้อมูลห้องพักในกรุงเทพ

ข้อมูลภาพนิ่ง ข้อความ ข้อมูลสถิติ
ข้อมูลรูปแบบแผนที่

Price per person: ฿ 0 - ฿ 6,473,568

Star rating: ★★★★★ (444)

Location rating: 9+ Exceptional location (666)

Search results for: What are you looking for?

Agoda Preferred Property

Jasmine City Hotel
★★★★★ Excellent 7,148 reviews
฿ 6,377

Agoda Preferred Property

Al Meroz Hotel Bangkok- The Leading Halal Hotel
★★★★★ Excellent 1,105 reviews
฿ 4,909

Agoda Preferred Property

Vic3 Bangkok

ตย. คุณลักษณะ Big data : Veracity

- คุณภาพหรือความน่าเชื่อถือของข้อมูล
- ข้อมูลที่ไม่มีอคติ ไม่มีBugs Noise ข้อมูลมีความปลอดภัย แหล่งที่มา ข้อมูล ความไม่แน่นอน Out of Date หรือเกิดจาก Human error

ตย. คุณลักษณะ Big data : Value

Usefulness of data for an enterprise


Valuable Data

- Customer Lifetime Value
- Average Order Value
- Cancellation Rate

Data With No Value

- Data with missing or corrupt values
- Data missing key structured elements such as customer reference or date

Types of Data




Connected building	Motion sensor	Door sensor	Button	Bed	Plug	Light	Medical	Camera	Central
 Fibaro flood sensor  Intervox smoke detector  Sensing labs humidity sensor  Sensing labs temperature sensor  FHE Sensor Pilot	 Tunstall  Beewi  Eldes  Intervox  Fibaro  FHE	 Tunstall  Beewi  Eldes  Intervox  Fibaro  FHE	 Tunstall  Intervox  Vitalbase Fall detector  Vivago watch	 Emfit  Telehealth	 MyPlug - Orange  Smartplug - Beewi  Otio  FHE Smart Plug	 Intervox	 Bewell glucose meter  Bewell blood pressure monitor  Bewell oximeter  Bewell thermometer  Bewell electro-cardiogram  Bathroom scale  Connected watch	 Vivotek  Kinect	 Tunstall  Intervox

Sensor data:

Human-generated data


65



- แหล่งสร้างข้อมูล เช่น โซเชียล มีเดีย Blog posts อีเมล ภาพ ข้อความที่แชร์กัน

ตัวอย่าง

- ผู้ประกอบการ 1 ราย Live จำหน่ายสินค้า มียอดวิว 210 K มีคนมาเมนต์ 709 ข้อความ ยอดแชร์จากคลิปนี้ 276 ครั้ง
- คุณเคยนับหรือไม่ว่าสร้างข้อมูลในช่องทางต่าง ๆ เท่าไหร่ อย่างไร





ภาพจาก: Erl, T., Khattak, W. and Buhler, P. (2016). Big Data Fundamentals: Concepts, Divers and Techniques

Machine-generated data

66

แหล่งข้อมูลจาก web logs ข้อมูลจากเซ็นเซอร์ ข้อมูลจากเครื่องใช้ ตู้เย็น Smart meter และอื่น ๆ



ภาพจาก: Erl, T., Khattak, W. and Buhler, P. (2016). Big Data Fundamentals: Concepts, Divers and Techniques

Structured Data Example

 **สินค้า** [+ สินค้าใหม่](#)

🔍 **นมดื่ม**

ผลการค้นหา 2 รายการ

แสดง ทั้งหมด [เปิดใช้งาน](#)



นมดื่มเกษตรมช. ขนาด 1 ลิตร (Pre-Order 2 วัน)

 **ของดื่มช.**  **cmu** **#CMUCarelicious** **#อาหารปลอดภัย** **#ข้าวฟักผลไม้ปลอดสารพิษ** **#สินค้าปลอดภัย**

#ของดื่มช. **#มชCMU**

ราคา **฿65.00**



นมดื่มเกษตร มช.

 **ของดื่มช.**  **cmu** **#CMUCarelicious** **#อาหารปลอดภัย** **#ข้าวฟักผลไม้ปลอดสารพิษ** **#สินค้าปลอดภัย**

#ของดื่มช. **#มชCMU**


ราคา **฿20.00**

E-Commerce ประกอบด้วย

- Product Catalog Systems
- Member System
- Shopping Cart

ภาพจาก: cmuselectedproducts.com

Unstructured Data Example



video



image
files



audio

ภาพจาก: Erl, T., Khattak, W. and Buhler, P. (2016). Big Data Fundamentals: Concepts, Divers and Techniques

Semi-structured Data Example



ตัวอย่าง

- E-mails
- XML and other markup languages
- Binary executables
- TCP/IP packets
- Zipped files
- Integration of data from different sources
- Web pages

ภาพจาก: Erl, T., Khattak, W. and Buhler, P. (2016). Big Data Fundamentals: Concepts, Divers and Techniques

Advantages of Semi-structured Data

- The data is not constrained by a fixed schema
- Flexible i.e Schema can be easily changed.
- Data is portable
- It is possible to view structured data as semi-structured data
- Its supports users who can not express their need in SQL
- It can deal easily with the heterogeneity of sources.

Difference between Structured, Semi-structured and Unstructured data

71

ข้อมูลมีโครงสร้าง	ข้อมูลกึ่งโครงสร้าง	ข้อมูลไม่มีโครงสร้าง
ข้อมูลจัดเก็บในฐานข้อมูล แบบ Database SQL รูปแบบตารางข้อมูล (แถวและคอลัมน์)	ไม่ขึ้นหรือผูกติดกับฐานข้อมูลใด ฐานข้อมูลหนึ่ง	ข้อมูลที่ไม่มีโครงสร้างเป็นข้อมูลที่ไม่ได้จัดระเบียบตามลักษณะที่กำหนดไว้ล่วงหน้า
ออกแบบรูปแบบข้อมูลที่จัดเก็บแต่ละ คอลัมน์	โครงสร้าง และคุณสมบัติเหมาะกับการนำไปวิเคราะห์ต่างแพลตฟอร์ม	ไม่มีโมเดลข้อมูลที่กำหนดไว้ล่วงหน้า
ระบบฐานข้อมูลเชิงสัมพันธ์	ข้อมูลที่ไม่ได้อยู่ในฐานข้อมูลเชิงสัมพันธ์ แต่มีคุณสมบัติขององค์กรบางประการที่ช่วยให้วิเคราะห์ได้ง่ายขึ้น	ไม่เหมาะสำหรับฐานข้อมูลเชิงสัมพันธ์ กระแสหลัก

ในองค์กรของคุณมีข้อมูลแบบนี้ไหม

จับผิดข้อมูลจากสองภาพนี้

GUEST DETAILS



Flight 1: Chiang Mai → Penang		
Chiang Mai to Kuala Lumpur		
Ms Sirikorn Santirojanakul	• Checked baggage 20kg	
Mr Phusit Kornsurin	• No Add-ons	
Kuala Lumpur to Penang		
Ms Sirikorn Santirojanakul	• Checked baggage 20kg	
Mr Phusit Kornsurin	• No Add-ons	
Flight 2: Penang → Chiang Mai		
Penang to Bangkok - Don Mueang		
Ms Sirikorn Santirojanakul	• Checked baggage 20kg	
Mr Phusit Kornsurin	• No Add-ons	
Bangkok - Don Mueang to Chiang Mai		
Ms Sirikorn Santirojanakul	• Checked baggage 20kg	

AIRASIA BERHAD (284669-W)
RedQ, Jalan Pekeliling 5,
Lapangan Terbang Antarabangsa Kuala Lumpur (KLIA2)
64000 KLIA, Selangor Darul Ehsan
Malaysia

(GST Reg No: 001062207488)

Tax Invoice Number: AQTM6K_AK1804030002952
Printed Date: 4 Apr, 2018

TAX INVOICE

MR Sirikorn Santirojanakul
, Thailand
Mobile Phone: 66635395159

Date of Invoice: 3/4/2018 (02:57:50 PM)


No.	Description	Total Excl. GST	GST @ 6%
	FARE	THB	THB
1	2x Guests (CNX-PEN) **	4250.68	0.00
2	2x Guests (PEN-CNX) **	5190.46	0.00
3	4x Advance Passenger Processing Service **	140.00	0.00
4	4x International Arrival and Departure Fees (Thailand) **	60.00	0.00
5	2x Excise Tax (Fuel) *	300.00	0.00
6	2x Passenger Service Charge *	560.00	0.00

Big Data Ecosystem

- การรวบรวมกระบวนการวิเคราะห์และรายงานข้อมูล
- โครงสร้างพื้นฐานและเครื่องมือสำหรับกระบวนการ / การวิเคราะห์
- รายงาน

กระบวนการ Big Data

1. Ingest (การจัดเก็บรวบรวมข้อมูล)
2. Process (การประมวลผล)
3. Publish (การเผยแพร่)
4. Report (รายงาน)



© Matt Turck (@mattturck), Sutian Dong (@sutiandong) & FirstMark Capital (@firstmarkcap)


INFRASTRUCTURE

75



- โครงสร้างพื้นฐานเป็นส่วนสำคัญของระบบนิเวศข้อมูลขนาดใหญ่
- ในการประมวลผลจัดเก็บและวิเคราะห์ข้อมูล ในอดีตจะใช้ฐานข้อมูลเชิงสัมพันธ์
- เมื่อปริมาณข้อมูล ความเร็วและข้อมูลที่มีความหลากหลายมากขึ้น และในการจัดการข้อมูลขนาดใหญ่ มีความซับซ้อน การเพิ่มขึ้นของข้อมูลที่ไม่มีโครงสร้าง ทำให้การจัดเก็บในฐานข้อมูลเชิงสัมพันธ์ขาดประสิทธิภาพ
- ทำให้ต้องใช้เทคโนโลยีโครงสร้างพื้นฐานแบบใหม่ เพื่อรองรับข้อมูลรูปแบบใหม่และข้อมูลขนาดหลายพันเทราไบต์

INFRASTRUCTURE



- ตัวอย่างของเทคโนโลยีของ Infrastructure
- Hadoop – เป็นเทคโนโลยีทั้งหมดของระบบ ที่ออกแบบมา เพื่อจัดเก็บ ประมวลผล และวิเคราะห์ข้อมูล โดยหลักการสำคัญของเทคโนโลยี Hadoop คือ การทำงานบนหลักการของแยกและกระจายข้อมูลเป็นส่วนๆ
- NoSQL – ใช้สำหรับทำงานในการประมวลผลข้อมูลจำนวนมาก ๆ ของข้อมูล ที่มีโครงสร้างหลากหลาย โดยฐานข้อมูล NoSQL ส่วนใหญ่นั้นจะทำงานกับ ข้อมูลที่ไม่ต่อเนื่อง กับข้อมูลที่มีโครงสร้างหลากหลาย และบางตัวยังสามารถ ทำงานกับ Hadoop ได้อีกด้วย
- Massively Parallel Processing (MPP) Databases – ฐานข้อมูล MPP ทำ งานกับข้อมูลที่เป็นส่วน ๆ ข้ามโหนดต่าง ๆ และประมวลผลข้อมูลแบบ ขนาน และใช้ SQL โดย MPP จะทำงานบนฮาร์ดแวร์ที่ราคาแพง

Analytics/Process



- แม้ว่าเทคโนโลยีโครงสร้างพื้นฐานจะรวมการวิเคราะห์ข้อมูล แต่ก็มีเทคโนโลยีเฉพาะที่ออกแบบมาพร้อมความสามารถในการวิเคราะห์ข้อมูล โดยจะมีส่วนย่อยของงานในส่วนนี้ดังนี้
- Analytics Platforms – ทำหน้าที่รวบรวมและวิเคราะห์ข้อมูลไปเป็นรายงาน เพื่อช่วยในการตัดสินใจ เน้นเฉพาะเรื่องที่เราสงสัยและนำเสนอข้อมูลเชิงลึกเพื่อให้ผู้ใช้ปลายทางสามารถใช้งานได้อย่างทันที่ว่างที่สุด
- Visualization Platform – เพื่อออกแบบนำเสนอในรูปแบบที่ซับซ้อน จากข้อมูลดิบ เพื่ออธิบายข้อมูลได้
- Business Intelligence (BI) Platforms – ใช้การบูรณาการและวิเคราะห์ข้อมูลทางธุรกิจ ซึ่ง BI Platform ใช้วิเคราะห์ข้อมูลจากหลายแหล่ง เพื่อนำเสนอบริการ ทั้ง Business Intelligence Report, Dashboard และ Visualization
- Machine Learning - เป็นส่วนของการเรียนรู้จากข้อมูล ความสัมพันธ์ต่าง ๆ ของข้อมูลที่เกิดขึ้น ด้วยตัวเอง เพื่อใช้ในการตอบคำถามต่าง ๆ ในอนาคต

Application



- Application เป็นเครื่องมือที่จะช่วยให้ผู้ใช้งาน สามารถวิเคราะห์ Big Data เพื่อให้ได้มาซึ่งข้อมูลเชิงลึก ซึ่งจะมีตัวอย่าง Application ในด้านต่าง ๆ ดังนี้
- ด้านสุขภาพ Application Minitabs ที่สรุปของการสแกนสมองแบบ 3 มิติและข้อมูลเกี่ยวกับระบบประสาทที่สามารถเข้าถึงได้โดยนักประสาทวิทยาจากทั่วโลกและช่วยในการวินิจฉัยการพยากรณ์โรคและการรักษาผู้ป่วยโรคสมองเสื่อม
- ด้านค้าปลีก Avansera สามารถเอาแอปพลิเคชันการช้อปปิ้งบนมือถือที่นำเสนอข้อมูลเชิงลึกสำหรับ บริษัท ผู้ผลิตอาหารเป็นตัวแปรที่มีผลต่อการซื้ออาหารเช่นความภักดีของแบรนด์และความยืดหยุ่นของราคา
- ด้านพลังงาน AutoGrid ใช้ข้อมูลจากสมาร์ทเมตรระบบการจัดการอาคารตัวควบคุมแรงดันไฟฟ้าและเครื่องควบคุมอุณหภูมิเพื่อช่วยให้ผู้บริโภคดีติดตามและลดการใช้พลังงานลดของเสียสมดุลระบบกริดปรับปรุงการดำเนินงานของระบบและคาดการณ์การบริโภคในอนาคตได้

Big Data: Technology

• Storage และ Analytics



Big Data: Technology

• Storage และ Analytics




เทคโนโลยีสำหรับ Big Data

- Storage
- ฐานข้อมูล RDBMS แบบเดิม ก็ยังเป็นเทคโนโลยีที่เหมาะสมที่สุดในการเก็บข้อมูลแบบ Structure แต่ถ้าข้อมูลมีขนาดใหญ่มากก็จะเจอปัญหาเรื่องต้นทุนที่สูง และหากข้อมูลมีจำนวนเป็น PetaByte ก็คงยากที่จะเก็บ ถึงแม้ในปัจจุบันจะมี MPP Database อย่าง Oracle ExaDta หรือ SAP HANA แต่มีค่าใช้จ่ายสูง
- Hadoop HDFS เป็นเทคโนโลยีที่มีเริ่มใช้งาน หน่วยงานส่วนใหญ่เริ่มวางแผนจะต้องใช้ในอนาคต เพราะมีความต้องการเก็บข้อมูลขนาดใหญ่ทั้งที่เป็น Unstructure Data หรือนำข้อมูลที่เป็น structure มาเก็บไว้ โดยสามารถจะเก็บข้อมูลได้เป็น PetaByte ทั้งนี้ขึ้นอยู่กับจำนวนเครื่องที่มีอยู่ในลักษณะ scale-out ข้อสำคัญ Hadoop มีต้นทุนที่ค่อนข้างต่ำเมื่อเทียบกับเทคโนโลยีการเก็บข้อมูลแบบอื่น

Hadoop

- ซอฟต์แวร์ประเภท open source ที่จัดทำขึ้นเพื่อเป็นแพลตฟอร์มในการจัดเก็บข้อมูล ซึ่งมีกรอบการทำงานเพื่อใช้ในการจัดเก็บข้อมูลและประมวลผลข้อมูลที่มีขนาดใหญ่ สามารถปรับขยาย ยืดหยุ่น เพื่อรองรับข้อมูลที่มีจำนวนมากมายมหาศาลได้ ทั้งนี้ก็เพราะมันมีการกระบวนการประมวลผลที่แข็งแกร่งมากซึ่งเป็นผลมาจากการประมวลผลข้อมูลแบบกระจายผ่านเครื่องคอมพิวเตอร์ที่ถูกจัดอยู่ในรูปแบบ Cluster



เทคโนโลยีสำหรับ Big Data

- Storage
- NoSQL เป็นเทคโนโลยีที่ต้องการเก็บข้อมูลจำนวนมากกว่าของ RDBMS ในลักษณะ scale-out เป็นจำนวนหลาย TeraByte แต่อาจไม่ได้เน้นเรื่องความมั่นคงของข้อมูลมากนัก เหมาะกับ Application บางประเภท ทั้งนี้เราสามารถจะแบ่งเทคโนโลยี NoSQL ออกไปได้สี่กลุ่มคือ Column Oriented, Document Oriented, Key-Value และ Graph
- Cloud Storage ข้อมูลขนาดใหญ่ขององค์กรบางส่วนอาจต้องเก็บไว้ใน Public Cloud Storage เช่น Amazon S3 โดยเฉพาะข้อมูลภายนอกอาทิเช่น Social Media Data หรือข้อมูลที่เป็น Archiving ที่ไม่ได้มีความสำคัญมาก เพราะ Cloud Storage จะมีราคาในการเก็บที่ถูกสุด และสามารถที่จะเก็บได้โดยมีขนาดไม่จำกัด แต่ข้อเสียคือเรื่องความปลอดภัยและความเร็วในการถ่ายโอนข้อมูล

เทคโนโลยีสำหรับ Big Data

- การประมวลผลข้อมูลที่เป็น Big Data จะมีทั้งการวิเคราะห์ข้อมูลที่เป็น business intelligence (BI) เพื่อที่จะดึงข้อมูลมานำเสนอ หรือการทำ Predictive Analytics
- SQL ก็เป็นภาษาที่ยังต้องใช้ในการประมวลผลข้อมูลโดยเฉพาะ Structure Data ที่เก็บอยู่ใน RDBMS และสามารถประมวลผลแบบ RealTime ได้
- APIs ข้อมูลที่เก็บอยู่ใน Storage ต่าง ๆ ที่กล่าวมาข้างต้นเช่น NoSQL หรือ Cloud Storage อาจต้องพัฒนาโปรแกรมด้วยภาษาคอมพิวเตอร์ต่าง ๆ ในการประมวลผลข้อมูลโดยใช้ APIs ในการเข้าถึงข้อมูล

เทคโนโลยีสำหรับ Big Data

- MapReduce เป็นเทคโนโลยีที่พัฒนาโดย Google ในการประมวลผลข้อมูลที่อยู่ใน HDFS โดยใช้ภาษาคอมพิวเตอร์อย่าง Java ในการพัฒนาโปรแกรม โดยจะประมวลผลแบบ Batch และเป็นวิธีการประมวลผลที่มากับเทคโนโลยี Hadoop
- Hive หรือ Pig เป็นภาษาคัดลอก SQL หรือ Scripting ที่ทำให้เราสามารถประมวลผลข้อมูลที่อยู่ใน Hadoop HDFS ได้โดยไม่ต้องพัฒนาโปรแกรม MapReduce แต่ทั้งนี้ข้อมูลจะต้องอยู่ในรูปแบบที่เหมาะสมเช่น ไฟล์ csv หรือ ไฟล์ข้อความบางประเภท

เทคโนโลยีสำหรับ Big Data

- Impala เป็นภาษาคัดลอก SQL ที่ทำให้เราสามารถประมวลผลข้อมูลที่อยู่ใน Hadoop HDFS ได้ โดยทำงานได้รวดเร็วกว่า Hive มาก แต่มีข้อเสียคือเป็นภาษาที่เป็น proprietary ของ Cloudera
- Spark เป็นเทคโนโลยีที่สามารถประมวลผลข้อมูลขนาดใหญ่แบบ Real-time โดยอาจมี Data Source มาจากหลากหลายแหล่งเช่น RDBMS, Cloud Storage, NoSQL หรือ Hadoop ซึ่งสามารถเขียนโปรแกรมโดยใช้ภาษา Scala, Java, Python หรือจะเขียนโดยใช้ภาษาคัดลอก SQL ก็ได้ และมี Library สำหรับการทำ Data Science คือ MLlib เป็นเทคโนโลยีที่น่าสนใจมากอันหนึ่ง


เทคโนโลยีสำหรับ Big Data


- ภาษาและเทคโนโลยีในการทำ Machine Learning ซึ่งก็จะมีหลากหลายทั้ง R Hadoop, Mahout, Azure Machine Learning หรือ AWS ML
- เทคโนโลยีสำหรับการทำ Data Visualisation และ BI อาทิเช่น Tableau, Pentaho, SaS, Excel และอื่น ๆ


บุคลากรในการจัดการข้อมูลขนาดใหญ่

- ในการทำงานที่เกี่ยวข้องกับข้อมูลขนาดใหญ่ หรือการสร้างระบบนิเวศน์ของข้อมูลขนาดใหญ่ ประกอบไปด้วย 3 ผู้เชี่ยวชาญหลัก (Data Expert) 3 กลุ่มดังนี้
 1. Data System กลุ่มงานนี้จะมี Data Engineer ทำหน้าที่ในการออกแบบระบบการไหลของข้อมูล การจัดโครงสร้าง การจัดเก็บข้อมูล และช่องทางการนำผลลัพธ์ที่ได้จากการประมวลผลไปแสดงผล
 2. Data Modeling กลุ่มงานนี้จะมี Data Scientist ทำหน้าที่สร้างแบบจำลอง (Model) ที่เหมาะสม โดยการนำข้อมูลขนาดใหญ่เป็นต้นแบบ และมองหาผลลัพธ์เชิงลึก (Insight) จากการสร้าง Data Model
 3. Data Communication กลุ่มงานนี้จะมี Data Analyst ทำหน้าที่ใช้ข้อมูลผลลัพธ์ที่ได้จาก Model ไปใช้งานและสื่อสารต่อ และยังเป็นผู้ประเมินปัญหา และประเมินผลลัพธ์จาก Model

People







Career Path ของ Data Expert

1. **Data Engineer** -> Chief Technology Officer (CTO) หรือ ผู้บริหารระดับสูงด้านเทคโนโลยี
2. **Data Scientist** -> Specialist -> Chief Information Officer (CIO) หรือ ผู้บริหารเทคโนโลยีสารสนเทศระดับสูง
3. **Data Analyst** -> Business Analyst -> Chief Marketing Officer (CMO)
Chief Financial Officer (CFO)
Chief Operating Officer (COO)
Chief Executive Officer (CEO)

Skills

93

	Data Analyst	Machine Learning Engineer	Data Engineer	Data Scientist
Programming Tools	Very important	Very important	Very important	Very important
Data Visualization and Communication	Very important	Somewhat important	Somewhat important	Very important
Data Intuition	Somewhat important	Very important	Somewhat important	Very important
Statistics	Somewhat important	Very important	Somewhat important	Very important
Data Wrangling	Not that important	Not that important	Very important	Very important
Machine Learning	Not that important	Very important	Not that important	Very important
Software Engineering	Not that important	Somewhat important	Very important	Somewhat important
Multivariable Calculus and Linear Algebra	Not that important	Very important	Not that important	Somewhat important
Not that important Somewhat important Very important				

ตัวอย่างการนำไปใช้

Big Data for Organization Data Disruption

- ภาคเอกชนและภาครัฐ

กรณีศึกษาตัวอย่างของการใช้ข้อมูลขนาดใหญ่

- จับผู้ร้ายด้วย Big Data:
- Beware ระบบประเมินความเสี่ยงการก่ออาชญากรรมรายบุคคล
- Beware ถูกพัฒนาโดยบริษัท Intrado ด้วยแนวคิดในการรวบรวมประวัติรายบุคคลของประชากรทั้งหมด เข้ามาผูกกับข้อมูลที่มีในฐานข้อมูลต่าง ๆ, ข้อมูลบน Web Site รวมถึง Social Network และทำการประเมินความเสี่ยงในการก่ออาชญากรรมด้วยระบบ Scoring เพื่อให้คะแนนแต่ละคนจากประวัติ, ข้อมูล และความสัมพันธ์ระหว่างบุคคลต่าง ๆ ได้แบบ Real-time ทำให้เจ้าหน้าที่ที่รับเรื่องด่วนผ่าน 911 หรือเจ้าหน้าที่ที่กำลังไปปฏิบัติการสามารถเข้าใจในสถานการณ์และความเสี่ยงได้อย่างรวดเร็วจากการวิเคราะห์ Big Data เหล่านี้

กรณีศึกษาตัวอย่างของการใช้ข้อมูลขนาดใหญ่

96


- จับผู้ร้ายด้วย Big Data:
- ShotSpotter ระบบระบุจุดเกิดเหตุยิงปืน
- ด้วยการติดตั้งไมโครโฟนเอาไว้ทั่วเมือง และมีระบบวิเคราะห์เพื่อระบุเสียงปืนที่ได้ยินจากไมโครโฟนแต่ละตัว และทำการค้นหาตำแหน่งจากไมโครโฟนที่ได้ยินเสียงในระดับและเวลาที่แตกต่างกันจากหลายๆ จุดนั้น ก็ทำให้ตำรวจสามารถสืบเสาะหาจุดเกิดเหตุยิงปืนได้อย่างรวดเร็วยิ่งขึ้นได้แล้ว

กรณีศึกษาตัวอย่างของการใช้ข้อมูลขนาดใหญ่

- จับผู้ร้ายด้วย Big Data:
- Media Sonar ระบบวิเคราะห์หาความเสี่ยงการเกิดอาชญากรรมจาก Social Media
- ตำรวจสามารถติดตามข้อความต่าง ๆ ที่ประชาชนโพสต์อยู่บน Social Media เพื่อประเมินความเสี่ยงในการเกิดอาชญากรรมหรือค้นหาเหตุอาชญากรรมที่กำลังเกิดขึ้นได้ทันที โดยเฉพาะเหตุต่าง ๆ ที่อาจเกิดขึ้นกับสถาบันการศึกษา และข้อความจากสมาชิกแก๊งโจรต่าง ๆ ในเมืองได้แบบ Real-time


ETL: Extract, Transform, Load

- เป็นการนำข้อมูล (Extract) จากหลากหลายแหล่งข้อมูล เช่น จากฝ่าย Marketing, จากฝ่าย Sale, จากฝ่าย Customer Service ฯลฯ มาแปลงรูปแบบให้เหมาะสม (Transform) แล้วเก็บ (Load) เข้าไปใน Data Warehouse หรือ Data Lake




ETL: Extract, Transform, Load

- สามารถเอาข้อมูลชุดนี้ไปให้ทีม Analytics ประมวลผลต่อ หรือเอาไปทำ Dashboard สรุปให้ผู้บริหาร
- หรือนำข้อมูลระบบเก่า (Legacy System) มารวมกับระบบใหม่



Scaling up




- To scale up the system
- เพิ่มความเร็วการทำงาน เพิ่มประสิทธิภาพ ETL
- เลือกใช้ HDD ที่มีประสิทธิภาพอ่านเขียนข้อมูลเร็ว
- เพิ่ม RAM CPU Network เพื่อเพิ่มประสิทธิภาพการประมวลผล

Scaling Out

- Scaling out แนวทางการดำเนินการจะตรงข้ามกับ Scaling up
- จะสร้างระบบที่ใหญ่ขึ้นเป้าหมายคือการกระจายภาระการประมวลผลระหว่างระบบขนาดเล็กจำนวนมากแทน
- วิธีที่ง่ายที่สุดในการปรับขนาดฐานข้อมูล SQL คือการใช้เครือข่ายพื้นที่เก็บข้อมูล (SAN) เพื่อจัดเก็บข้อมูล
- จากนั้นใช้เซิร์ฟเวอร์ SQL ค้นหาข้อมูลโดยใช้ภาษาแบบสอบถาม วิธีนี้จะกระจายโหลดระหว่างเซิร์ฟเวอร์ทั้งหมดที่ทำงานร่วมกัน

Scaling out a SQL Database



102

What is ELT?

- ELT หมายถึง “extract, load, and transform”
- The processes a data pipeline uses to replicate data from a source system into a target system such as a cloud data warehouse.

ELT

- **Extraction:** This first step involves copying data from the source system.
- **Loading:** During the loading step, the pipeline replicates data from the source into the target system, which might be a data warehouse or data lake.
- **Transformation:** Once the data is in the target system, organizations can run whatever transformations they need. Often organizations will transform raw data in different ways for use with different tools or business processes.

ELT — the next generation of ETL

- ELT is a modern variation on the older process of extract, transform, and load (ETL), in which transformations take place before the data is loaded.
- Running transformations before the load phase results in a more complex data replication process.