

**Big Data** การใช้ประโยชน์จากกระบวนการรวบรวม การจัดเก็บ การประมวลผล และการวิเคราะห์ข้อมูลที่มีความหลากหลาย มีปริมาณมหาศาล และสามารถใช้งานได้อย่างรวดเร็ว

**Why Big Data (เหตุผลสำคัญของการใช้ Big Data):** 1.Cost Reduction (ลดต้นทุน) 2.Faster, Better Decision Making (ตัดสินใจได้เร็วขึ้นและดียิ่งขึ้น) 3.New Products & Services (ผลิตภัณฑ์และบริการใหม่)

**Big Data terminology**

**Datasets:** ชุดข้อมูลหรือกลุ่มข้อมูลที่เกี่ยวข้องกัน ซึ่งอาจอยู่ในหลากหลายรูปแบบเช่นไฟล์ข้อมูล รูปภาพ ตารางข้อมูล เป็นต้น

**Data Cleansing** กระบวนการตรวจสอบ การแก้ไข การลบ เพื่อให้รายการข้อมูลที่ไม่ถูกหรือไม่สอดคล้องกันออกไป

**Data Analysis** กระบวนการนำข้อมูลมาเรียบเรียง จัดกลุ่ม/แยกประเภทชุดข้อมูล หาความสัมพันธ์ของชุดข้อมูลแต่ละชุดในรูปแบบต่างๆ เพื่อหาเป้าหมายหรือวัตถุประสงค์ต่างๆ จนได้เป็นข้อมูลเชิงลึกหรือข้อสรุป ที่ช่วยในการหาสาเหตุเข้าใจสถานการณ์ หรือสนับสนุนการตัดสินใจ

**Data Analytics** การวิเคราะห์ข้อมูลต่างๆ เพื่อช่วยให้ธุรกิจสามารถบรรลุวัตถุประสงค์ โดยนำข้อมูลในอดีต ปัจจุบัน รวมถึงการพยากรณ์ข้อมูลในอนาคต เพื่อใช้ในการกำหนดกลยุทธ์ต่างๆในการสร้างกลยุทธ์ให้กับธุรกิจได้

**-Descriptive Analytics:** การวิเคราะห์เชิงพรรณนาเป็นรูปแบบการใช้ข้อมูลแบบพื้นฐานโดยเน้นการอธิบายการเกิดเหตุการณ์ต่างๆในอดีต เช่น รายงานธุรกิจ รายงานด้านการทำโฆษณา

**-Diagnostic Analytics:** เป็นการวิเคราะห์เชิงวินิจฉัยหาสาเหตุ โดยเปรียบเทียบข้อมูลในอดีตเทียบกับข้อมูลอื่นเพื่อตอบคำถามว่าทำไมบางสิ่งเกิดขึ้น การวิเคราะห์เชิงวินิจฉัยทำให้มีความเป็นไปได้ที่จะเจาะลึกค้นหา การอ้างอิงและระบุรูปแบบจากข้อมูลเชิงลึกเกี่ยวกับปัญหาเฉพาะแต่จะต้องมีข้อมูลที่มีความละเอียดมากพอ

**-Predictive Analytics:** เป็นการวิเคราะห์เชิงพยากรณ์รูปแบบการใช้ข้อมูลที่มีความซับซ้อน โดยเป็นการ พยากรณ์ หรือ ทำนายสิ่งที่กำลังเกิดขึ้น โดยใช้ข้อมูลในอดีตร่วมกับโมเดลทางคณิตศาสตร์ต่างๆ ร่วมกับการทำ Data Mining สามารถวิเคราะห์หาโอกาสและความเสี่ยงต่างๆที่จะเกิดขึ้นในอนาคตได้ด้วย เช่น การรู้แนวโน้มทางการตลาด การพยากรณ์ยอดขาย

**-Prescriptive Analytics:** เป็นการวิเคราะห์เชิงพยากรณ์และทางเลือกเป็นรูปแบบที่มีความซับซ้อนและยากที่สุด เพราะไม่เพียงพยากรณ์หรือทำนายว่าจะเกิดอะไรขึ้น แต่ยังให้คำแนะนำในทางเลือกต่างๆ โมเดลสามารถปรับเปลี่ยนได้ตามข้อมูลที่เพิ่มเติมเข้ามา ในรูปแบบนี้ยังเป็นการใช้ข้อมูลที่มากที่สุดและเกี่ยวข้องกับเรื่อง Big Data มากที่สุด

**- Business Intelligence (BI):** เป็นกระบวนการที่องค์กรจะใช้ขับเคลื่อนการดำเนินงานด้วยเทคโนโลยีโดยเน้นในด้านการวิเคราะห์ข้อมูลและนำเสนอข้อมูล สามารถนำไปช่วยให้ผู้บริหาร ผู้จัดการและผู้ใช้ในองค์กรสามารถตัดสินใจทางธุรกิจได้อย่างมีประสิทธิภาพ

**Characteristics of Big Data**

**3Vs** -Volume(ปริมาณข้อมูลขนาดใหญ่) Varity (ความหลากหลายของกลุ่มข้อมูล) Velocity(ความเร็วในการประมวลผล)

**5Vs** -Volume(ปริมาณข้อมูลขนาดใหญ่) Varity (ความหลากหลายของกลุ่มข้อมูล) Velocity(ความเร็วในการประมวลผล) -Value (คุณค่าของข้อมูล) -Veracity (คุณภาพหรือความน่าเชื่อถือของข้อมูล)

**องค์ประกอบของ big Data 6v**

**1. ปริมาณ(Volume)** คือ ข้อมูลที่มีปริมาณมาก สามารถนำไปวิเคราะห์แล้วได้ผลที่สะท้อนความเป็นจริง

**2. ความหลากหลาย (Variety)** คือ รูปแบบของข้อมูลมีความหลากหลาย เช่น ตาราง ภาพ เสียง ที่สามารถนำมาวิเคราะห์ประกอบกันได้

**3. ความรวดเร็ว (Velocity)** คือ ข้อมูลที่ถูกเก็บมาอย่างต่อเนื่องและรวดเร็ว ทำให้สามารถวิเคราะห์และตอบสนองได้อย่างทันเวลาที่

**4. ความถูกต้อง (Veracity)** คือ ข้อมูลมีความน่าเชื่อถือ มีระบบในการยืนยันตรวจสอบความถูกต้องของข้อมูล

**5. คุณค่า (Value)** คือ ข้อมูลที่มีประโยชน์ต่อการตัดสินใจเชิงธุรกิจ และมีความสัมพันธ์เชื่อมโยงกับวัตถุประสงค์ของธุรกิจ

**6. ความแปรผัน (Variability)** คือ ข้อมูลที่มีความหลากหลายในการใช้งานสามารถนำมาปรับรูปแบบเพื่อวิเคราะห์ได้หลายมุม และรูปแบบ การจัดเก็บข้อมูลจะแตกต่างกันออกไปในแต่ละแหล่งข้อมูล

**Types of Data**

- **Human-generated data** แหล่งสร้างข้อมูล เช่น โซเชียล มีเดีย อีเมล ภาพ
- **Machine-generated data** แหล่งข้อมูลจาก web logs ข้อมูลจากเซ็นเซอร์ข้อมูลจากเครื่องใช้ ตู้เย็น Smart meter และอื่น ๆ
- **Structured Data Example** E-Commerce ประกอบด้วย- Product Catalog Systems – Member System – Shopping Cart
- **Unstructured Data Example** – video – image files – audio
- **Semi-structured Data Example** E-mails, XML and other markup languages, Binary executables, TCP/IP packets, Zipped files, Web pages

**Big Data Ecosystem** การรวบรวมกระบวนการวิเคราะห์และรายงานข้อมูล โครงสร้างพื้นฐานและเครื่องมือสำหรับกระบวนการวิเคราะห์รายงาน 1. Ingest (การจัดเก็บรวบรวมข้อมูล) 2. Process (การประมวลผล) 3. Publish (การเผยแพร่) 4. Report (รายงาน)

**INFRASTRUCTURE** เป็นส่วนสำคัญของข้อมูลขนาดใหญ่ในการประมวลผลจัดเก็บและวิเคราะห์ข้อมูล เมื่อข้อมูลที่มีความหลากหลายมากขึ้นการจัดการข้อมูลขนาดใหญ่มีความซับซ้อน การเพิ่มขึ้นของข้อมูลที่ไม่มีโครงสร้างทำให้การจัดเก็บในฐานข้อมูลเชิงสัมพันธ์ขาดประสิทธิภาพ ทำให้ต้องใช้เทคโนโลยีโครงสร้างพื้นฐานแบบใหม่ เพื่อรองรับข้อมูลรูปแบบใหม่และข้อมูลขนาดใหญ่

**ตัวอย่างของเทคโนโลยีของ Infrastructure** 1.Hadoop เป็นเทคโนโลยีทั้งหมดของระบบที่ออกแบบมาเพื่อจัดเก็บ ประมวลผล และวิเคราะห์ข้อมูล โดยหลักการสำคัญของเทคโนโลยี Hadoop คือ การทำงานบนหลักการของแยกและกระจายข้อมูลเป็นส่วนๆ

**2. NoSQL** ใช้สำหรับทำงานในการประมวลผลข้อมูลจำนวนมาก ๆ ของข้อมูลที่มีโครงสร้างหลากหลาย โดยฐานข้อมูล NoSQL ส่วนใหญ่นั้นจะทำงานกับข้อมูลที่ไม่ต่อเนื่อง กับข้อมูลที่มีโครงสร้างหลากหลาย และบางตัวยังสามารถทำงานกับ Hadoop ได้อีกด้วย

**3. Massively Parallel Processing (MPP) Databases** ฐานข้อมูล MPP ทำงานกับข้อมูลที่เป็นส่วน ๆ ข้ามโหนดต่าง ๆ และประมวลผลข้อมูลแบบขนาน และใช้ SQL โดย MPP จะทำงานบนฮาร์ดแวร์ที่ราคาแพง

**Analytics/Process** แม้ว่าเทคโนโลยีโครงสร้างพื้นฐานจะรวมการวิเคราะห์ข้อมูล แต่ก็มีเทคโนโลยีเฉพาะที่ออกแบบมา พร้อมความสามารถในการวิเคราะห์ข้อมูล โดยจะมีส่วนย่อยของงานในส่วนนี้ดังนี้

**1. Analytics Platforms** ทำหน้าที่รวบรวมและวิเคราะห์ข้อมูลไปเป็นรายงาน เพื่อช่วยในการตัดสินใจ เน้นเฉพาะเรื่องที่สนใจ ข้อมูลเชิงลึกเพื่อให้ผู้ใช้ปลายทางสามารถใช้งานได้อย่างทันทั่วทั้งที่ที่สุด

**2. Visualization Platform** เพื่อออกแบบนำเสนอในรูปแบบที่ซับซ้อน จากข้อมูลดิบเพื่ออธิบายข้อมูลได้

**3. Business Intelligence (BI) Platforms** ใช้การบูรณาการและวิเคราะห์ข้อมูลทางธุรกิจ ซึ่ง BI Platform ใช้วิเคราะห์ข้อมูลจากหลายแหล่ง

เพื่อนำส่งบริการทั้ง Business Intelligence Report, Dashboard และ Visualization

**4. Machine Learning** เป็นส่วนของการเรียนรู้จากข้อมูลความสัมพันธ์ต่าง ๆ ของข้อมูลที่เกิดขึ้น ด้วยตัวเอง เพื่อใช้ในการตอบคำถามต่าง ๆ

**Application** เป็นเครื่องมือที่จะช่วยให้ผู้ใช้งาน สามารถวิเคราะห์ Big Data เพื่อให้ได้มาซึ่งข้อมูลเชิงลึก ซึ่งจะมีตัวอย่าง Application ในด้านต่าง ๆ ดังนี้

**1. ด้านสุขภาพ Application** Minitabs ที่สรุปของการสแกนสมองแบบ 3 มิติและข้อมูลเกี่ยวกับระบบประสาทที่สามารถเข้าถึงได้โดยนักประสาทวิทยาจากทั่วโลกและช่วยในการวินิจฉัยการพยากรณ์โรคและการรักษาผู้ป่วยโรคสมองเสื่อม

**2. ด้านค้าปลีก** Avansera สามารถเอาแอปพลิเคชันการช้อปปิ้งบนมือถือที่นำเสนอข้อมูลเชิงลึกสำหรับ บริษัท ผู้ผลิตอาหารเป็นตัวแปรที่มีผลต่อการซื้ออาหาร เช่น ความภักดีของแบรนด์และความยืดหยุ่นของราคา

**3. ด้านพลังงาน** AutoGrid ใช้ข้อมูลจากสมาร์ทเมตรระบบการจัดการอาคารควบคุมแรงดันไฟฟ้าและเครื่องควบคุมอุณหภูมิเพื่อช่วยให้ผู้บริโภคติดตามและลดการใช้พลังงานลดของเสียสมดุลระบบกริดปรับปรุงการดำเนินงานของระบบและคาดการณ์การบริโภคในอนาคตได้

**บุคลากรในการจัดการข้อมูลขนาดใหญ่** มี 3 ผู้เชี่ยวชาญหลัก (Data Expert) ดังนี้

**1. Data System** กลุ่มงานนี้จะจะมี Data Engineer ทำหน้าที่ในการออกแบบระบบการไหลของ ข้อมูล การจัดโครงสร้าง การจัดเก็บข้อมูล และช่องทางการนำผลลัพธ์ที่ได้จากการประมวลผลไปแสดงผล

**2. Data Modeling** กลุ่มงานนี้จะจะมี Data Scientist ทำหน้าที่สร้างแบบจำลอง (Model) ที่เหมาะสมโดยการนำข้อมูลขนาดใหญ่เป็นต้นแบบ และมองหาผลลัพธ์เชิงลึก (Insight) จากการสร้าง Data Model

**3. Data Communication** กลุ่มงานนี้จะจะมี Data Analyst ทำหน้าที่ใช้ข้อมูลผลลัพธ์ที่ได้จาก Model ไปใช้งานและสื่อสารต่อ และยังเป็นผู้ประเมินปัญหา และประเมินผลลัพธ์จาก Model

**People**

**Data System** – Data Engineer ออกแบบระบบ ข้อมูล

**Data Modeling** – Data Scientist ออกแบบ Model

**Data Communication** – Data Analyst ใช้ผลของ Model และสื่อสาร

**Career Path ของ Data Expert**

**1. Data Engineer** -> Chief Technology Officer (CTO) หรือ ผู้บริหารระดับสูงด้านเทคโนโลยี

**2. Data Scientist** -> Specialist ->Chief Information Officer (CIO) หรือ ผู้บริหารเทคโนโลยีสารสนเทศระดับสูง

**3. Data Analyst** ->Business Analyst -> Chief Marketing Officer (CMO), Chief Financial Officer (CFO), Chief Operating Officer (COO), Chief Executive Officer (CEO)

**ETL: Extract, Transform, Load** เป็นการนำข้อมูล (Extract) จากหลากหลายแหล่งข้อมูล เช่น จากฝ่าย Marketing, จากฝ่าย Sale, จากฝ่าย Customer Service ฯลฯ มาแปลงรูปแบบให้เหมาะสม (Transform) แล้วเก็บ (Load) เข้าไปใน Data Warehouse หรือ Data Lake สามารถเอาข้อมูลชุดนี้ไปให้ทีม Analytics ประมวลผลต่อ หรือเอาไปทำ Dashboard สรุปให้ผู้บริหารหรือนำข้อมูลระบบเก่า (Legacy System) มารวมกับระบบใหม่.

**Scaling up** คือการเพิ่มขีดความสามารถของระบบหรือโครงสร้างพื้นฐานเพื่อจัดการข้อมูลขนาดใหญ่ที่ เพิ่มขึ้น โดยยังคงประสิทธิภาพในการประมวลผลข้อมูลและการทำงานของระบบไว้เหมือนเดิมหรือดียิ่งขึ้น

**Scaling Out** จะตรงข้ามกับ Scaling up จะสร้างระบบที่ใหญ่ขึ้นเป้าหมายคือการกระจายภาระการประมวลผลระหว่างระบบขนาด

เล็กจำนวนมากแทน วิธีที่ง่ายที่สุดในการปรับขนาดฐานข้อมูล SQL คือการใช้เครือข่ายพื้นที่เก็บข้อมูล (SAN) เพื่อจัดเก็บข้อมูลจากนั้นใช้เซิร์ฟเวอร์ SQL ค้นหาข้อมูลโดยใช้ภาษาแบบสอบถาม วิธีนี้จะกระจายโหลดระหว่างเซิร์ฟเวอร์ทั้งหมดที่ทำงานร่วมกัน

บทที่ 3

**Business Case Evaluation** เป็นการประเมินการดำเนินการในกรณีต่างๆของธุรกิจที่กำหนดไว้อย่างชัดเจน โดยสร้างความเข้าใจในธุรกิจก่อนการวิเคราะห์ข้อมูล ทำให้ทราบวิสัยทัศน์ พันธกิจ เป้าหมาย กลยุทธ์ เป็นต้น

**แนวทางในการทำ BCE** Define the drivers ->State the problem->Formula alternative->Analyze the alternatives->Recommend and Report

**Data Identification** แหล่งที่มาของข้อมูล ระบุชื่อแหล่งที่มาให้ชัด ประเภทของข้อมูล เช่น ลักษณะของไฟล์

**Data Acquisition & Filtering** ข้อมูลจะถูกรวบรวมจากแหล่งข้อมูลทั้งหมดที่ระบุในขั้นตอนก่อนหน้าจากนั้นข้อมูลที่ได้มาจะถูกกรองโดยอัตโนมัติ การกรองข้อมูลที่เสียหาย หรือข้อมูลที่ไม่มีความค่าในการวิเคราะห์ออกไป

**Data Extraction** ข้อมูลบางส่วนที่ระบุว่าเป็นอินพุตสำหรับการวิเคราะห์อาจอยู่ในรูปแบบที่ไม่สอดคล้องกับโซลูชัน มีความจำเป็นในการระบุประเภทของข้อมูลที่แตกต่างกัน เมื่อต้องใช้ข้อมูลจากแหล่งภายนอก จึงต้องใช้การสกัดข้อมูลเพื่อแยกข้อมูลที่แตกต่างกัน และแปลงเป็นรูปแบบที่สามารถนำมาใช้ในการวิเคราะห์ที่ข้อมั้มักจะมีการซ้ำซ้อนในชุดข้อมูลต่างๆ ความซ้ำซ้อนนี้สามารถใช้เพื่อสำรวจชุดข้อมูลที่เชื่อมต่อกันเพื่อประกอบพารามิเตอร์ การตรวจสอบความถูกต้อง และกรอกข้อมูลที่ถูกต้องที่ขาดหายไป ข้อมูลที่ไม่ถูกต้องอาจทำให้ผลการวิเคราะห์ผิดพลาดได้

Data Validation & Cleansing

Big Data มักจะมีการซ้ำซ้อนในชุดข้อมูลต่างๆ ความซ้ำซ้อนนี้สามารถใช้เพื่อสำรวจชุดข้อมูลที่เชื่อมต่อกันเพื่อประกอบพารามิเตอร์การตรวจสอบความถูกต้องและกรอกข้อมูลที่ถูกต้องที่ขาดหายไป ข้อมูลที่ไม่ถูกต้องอาจทำให้ผลการวิเคราะห์ผิดพลาดได้

**Data Validation** “การตรวจสอบข้อมูล” เป็นส่วนสำคัญของงานจัดการข้อมูล ทั้งการรวบรวมข้อมูล การวิเคราะห์ข้อมูลหรือการเตรียมข้อมูลเพื่อนำเสนอข้อมูล

**แนวทางของ Data Validation** แนวทางที่ใช้ในการตรวจสอบความถูกต้องของข้อมูลคือแนวทางที่รับประกันความถูกต้องและความสมบูรณ์ของข้อมูล เช่น การตรวจสอบข้อมูล ความยาวรหัสผ่านขั้นต่ำ แต่ละองค์การใช้ข้อมูลจะต้องมีแนวทางของตนเองในการตรวจสอบ ข้อมูลเพื่อใช้งานข้อมูลอย่างมีประสิทธิภาพ ได้แก่ ตรวจสอบชนิดข้อมูล ตรวจสอบช่วงของข้อมูล ตรวจสอบข้อมูลเอกลักษณ์ ตรวจสอบความสอดคล้องของข้อมูล ตรวจสอบข้อมูลต้องไม่มีค่าว่าง

Data Cleansing?

Data cleansing หรือ data cleaning หรือ data scrubbing เป็นการทำความสะอาดข้อมูล เป็นกระบวนการตรวจสอบและการแก้ไข (หรือลบ) รายการข้อมูลที่ไม่ถูกต้องออกไปจากชุดข้อมูล

Data Aggregation & Representation

-เป็นกระบวนการรวบรวมข้อมูลและนำเสนอในรูปแบบสรุป  
-เป็นขั้นตอนที่สำคัญเนื่องจากความแม่นยำของข้อมูลเชิงลึกที่ได้จากการวิเคราะห์ข้อมูลขึ้นอยู่กับปริมาณและคุณภาพของข้อมูลที่ใช้  
-ข้อมูลอาจถูกรวบรวมจากหลายแหล่งเพื่อจุดประสงค์ในการรวมแหล่งข้อมูลเหล่านี้เป็นสรุปสำหรับการวิเคราะห์ข้อมูล

**Data Visualization** การสร้างภาพข้อมูล คือการสร้างและการศึกษาการแสดงผลภาพข้อมูล บางครั้งเรียกว่าการสื่อสารด้วยภาพหรือสถิติเชิงพรรณนาและรวมถึงเทคนิคในการนำเสนอ ข้อมูลในลักษณะที่เป็นภาพเพื่อการสื่อสารข้อมูลที่ชัดเจน

ลักษณะของ Data Visualization

• ใช้งานง่าย (Intuitive) • เข้าใจได้รวดเร็ว (Fast)

• ความยืดหยุ่น (Flexible) • ข้อมูลเชิงลึก (Insightful)

ปัจจัยประสิทธิผลในการทำ Visualization

•Visual cues / Visual encoding: การแปลงข้อมูลให้แสดงในลักษณะของรูปร่าง,สี,หรือขนาด

•Coordinate systems: ระบบพิกัดที่ช่วยทำให้เกิดพื้นที่ที่มีโครงสร้างสำหรับใส่ข้อมูลที่ต้องการแสดงรูปแบบพื้นฐานที่เห็นได้ทั่วไปคือ ระบบพิกัดที่มีแกน X

•Scale / Data types: จะต้องสอดคล้องกับระบบพิกัดข้างต้น โดย Data types พื้นฐานนั้นมีอยู่ ได้แก่ ข้อมูลเชิงตัวเลข ข้อมูลที่เป็นหมวดหมู่

•Context: ในกรณีที่มีผู้รับสารไม่คุ้นเคยกับข้อมูล เป็นหน้าที่ของ Data Scientist ที่จะต้องระบุบริบทของข้อมูลให้ชัดเจน

Visual Encoding

•Position: การระบุตำแหน่งของข้อมูลแต่ละจุด

•Length: การเข้ารหัสข้อมูลพื้นฐานอีกแบบหนึ่งคือการใช้ความยาว

•Angle: กราฟวงกลมหรือ Pie Chart •Direction: การใช้ทิศทาง

•Shape: รูปร่างหรือสัญลักษณ์สามารถใช้ในการจัดหมวดหมู่ให้กับข้อมูล

•Area / Volume: ขนาดในการเข้ารหัสข้อมูลได้ ขนาดที่ใหญ่กว่าแสดงถึงค่าที่มากกว่า

•Color: สามารถเข้ารหัสข้อมูลโดยใช้สีได้

Data Types: ประเภทข้อมูลพื้นฐาน

•Numeric: ใช้ในการแสดงข้อมูลเชิงปริมาณ

•Categorical: ใช้ในการแสดงข้อมูลคุณลักษณะ เช่น ตำแหน่งการเล่น

•Time Series: หมายถึงข้อมูลที่ถูกเก็บตามลำดับเวลา

ชนิดของ Visualizations

1. **Temporal** การสร้างภาพเชิงเวลา คล้ายกับการสร้างภาพข้อมูลเชิงเส้นแบบหนึ่งมิติ ข้อมูลเชิงเวลามีลักษณะรายการที่มีเวลาเริ่มต้นและสิ้นสุดและรายการอาจทับซ้อนกัน เช่น • Scatter plots • แผนภาพกระจาย • Timelines • Polar area diagrams • Time series sequences • Line graphs 2. **Hierarchical** การสร้างภาพข้อมูลประเภทลำดับชั้น จะใช้กับข้อมูลที่สามารถจัดเรียงในรูปแบบของต้นไม้ เป็นเทคนิคการสร้างภาพข้อมูลสำหรับชุดข้อมูลที่มีลำดับชั้นขนาดใหญ่ เช่น • Tree diagrams (Tree map) • Ring charts • Sunburst diagrams 3. **Network Data Visualization** เป็นกระบวนการของการนำเสนอเครือข่ายที่เชื่อมต่อการมองเห็น

เป็นลิงค์และโหนด 4. **Multidimensional** จะสัมพันธ์กับมิติของตัวแปรข้อมูล เช่น •Scatter plots •Pie charts •Venn diagrams

•Stacked bar graphs •Histograms 5. **Geospatial** การสร้างภาพข้อมูลเชิงพื้นที่ ที่เกี่ยวข้องกับสถานที่ทางกายภาพในชีวิตจริงซ้อนทับแผนที่ โดยมีจุดข้อมูลที่แตกต่างกัน เช่น • Flow map • Density map • Heat map การแสดงผลภาพของข้อมูลรูปแบบของ “สี” • Cartogram การนำเสนอข้อมูลสถิติในรูปแบบของแผนที่ซึ่งสามารถเปลี่ยนแปลงรูปทรงหรือพื้นที่ทางได้

คุณค่าของการแสดงผลภาพข้อมูล (The Value of Visualization)

การสร้างภาพข้อมูลเป็นวิธีการหนึ่งที่ทำให้ผู้ใช้สามารถได้รับข้อมูลเชิงลึกของประเด็นที่สนใจ สามารถจำแนกได้ดังนี้ 1. การสร้างภาพข้อมูลช่วยให้ผู้ชมทำความเข้าใจชุดข้อมูลขนาดใหญ่ได้ง่ายขึ้น 2. การสร้างภาพข้อมูลช่วยให้ผู้ใช้เข้าใจข้อมูลในระดับที่ใช้งานง่ายขึ้น 3. การสร้างภาพข้อมูลช่วยให้ผู้ใช้เห็นความสัมพันธ์ระหว่างชุดข้อมูล 4. การสร้างภาพข้อมูลสามารถช่วยเปลี่ยนมุมมองหรือพฤติกรรมของเราได้ **Big Data and Traditional Analytics Data Science/Data Mining Methods** เป็นขั้นตอนการวิเคราะห์ข้อมูลด้วยเทคนิค Data Mining 1. **การหาความสัมพันธ์**

(association analysis) หาความสัมพันธ์ของข้อมูลที่เกิดขึ้นร่วมกัน เช่น ค้นหาสินค้าที่มีการซื้อร่วมกันบ่อยๆ 2.**การจัดกลุ่มข้อมูล (clustering)** แบ่งข้อมูลหลายๆกลุ่มตามความคล้ายคลึง เช่น แบ่งกลุ่มลูกค้าตามพฤติกรรมการใช้งาน 3.**การจำแนกประเภทข้อมูล(classification)** สร้างโมเดลจากข้อมูลที่มีอยู่เพื่อทำนายอนาคต เช่น ทำนายปริมาณน้ำฝนที่ตกในวันถัดไป

**Segmentation by RFM** คือการแบ่งกลุ่มลูกค้าโดยใช้โมเดล RFM เพื่อวิเคราะห์พฤติกรรมของลูกค้า ซึ่งช่วยให้ธุรกิจเข้าใจลูกค้าและวางแผนกลยุทธ์ได้ตรงเป้าหมายมากขึ้น โดย RFM ประกอบด้วย 3 ปัจจัยหลัก:

1.**Recency (R):** ระยะเวลาที่ผ่านมานับตั้งแต่ลูกค้าทำธุรกรรมครั้งล่าสุด ยิ่งเวลาสั้นแปลว่าลูกค้ามีความใกล้ชิดกับธุรกิจมากกว่า 2.**Frequency (F):** ความถี่ในการทำธุรกรรมหรือติดต่อกับธุรกิจในช่วงระยะเวลาที่กำหนด ลูกค้าที่มีความถี่สูงมักจะถือว่าเป็นลูกค้าที่มีมูลค่ามากกว่า 3.**Monetary (M):** มูลค่าเงินที่ลูกค้าใช้จ่ายกับธุรกิจ ยิ่งใช้จ่ายสูงยิ่งแสดงถึงความสำคัญของลูกค้าต่อธุรกิจ

ขั้นตอนการทำงาน:

1.**เก็บข้อมูลลูกค้า:** เช่น วันที่ซื้อ ความถี่ และยอดการใช้จ่าย 2.**ให้คะแนน R, F, M:** แบ่งเป็นระดับ เช่น 1-5 โดยพิจารณาว่าใหม่บ่อย หรือใช้จ่ายมาก 3.**แบ่งกลุ่มลูกค้า:** ใช้คะแนนรวม RFM เพื่อจัดกลุ่ม เช่น กลุ่ม VIP: คะแนน R, F, M สูงทุกตัว (ลูกค้าคุณค่าสูงสุด) ,กลุ่มเริ่มหำง: R สูง แต่ F และ M เริ่มลดลง (ต้องกระตุ้น) ,กลุ่มไม่ประจำ: R ต่ำ แต่ F และ M ปานกลาง (ต้องดึงกลับมา) 4.**วางกลยุทธ์:** เช่น ให้โปรโมชั่นพิเศษกับ VIP หรือสร้างแคมเปญเรียกลูกค้าที่หายไป

Challenges for mining Big Data

1.**ข้อมูลที่หลากหลายและซับซ้อน (Heterogeneous and Complex Data)** ประเภทของข้อมูลมีความหลากหลาย เช่น ข้อมูลเครือข่ายสังคม (Social Network Data), ข้อมูลชีววิทยา (Biological Data), ข้อมูล GIS

เทคนิคการทำเหมืองข้อมูลควรพิจารณาถึง ความสัมพันธ์ในข้อมูล เช่น การเชื่อมโยงของกราฟ (network connectivity), มิติด้านเวลา และพื้นที่

2.**การปรับขนาด (Scalability)** ชุดข้อมูลที่มีขนาดหลายกิกะไบต์ หรือเทราไบต์กำลังกลายเป็นเรื่องปกติ เทคนิคการทำเหมืองข้อมูลสามารถปรับปรุงได้โดยใช้ การสุ่มตัวอย่าง (sampling) หรือการพัฒนา อัลกอริทึมแบบขนานหรือแบบกระจาย (parallel or distributed algorithms)

**Frequent itemset หรือ กลุ่มรายการที่เกิดขึ้นบ่อย** หมายถึงกลุ่มของสินค้าหรือรายการที่มักถูกซื้อหรือใช้งานร่วมกันในข้อมูลธุรกรรม (Transaction Data) โดยมีความถี่หรือจำนวนครั้งที่กลุ่มรายการนั้นปรากฏเกินค่าที่กำหนด (เรียกว่า Minimum Support Threshold)

**Sequential Pattern Mining** คือกระบวนการวิเคราะห์ข้อมูลเพื่อตรวจหา "ลำดับเหตุการณ์" หรือ "ลำดับรายการ" ที่เกิดขึ้นบ่อยในชุดข้อมูลที่มีลำดับเวลา (Sequential Data) ตัวอย่างเช่น ลำดับการซื้อสินค้า การเข้าชมเว็บไซต์ หรือกิจกรรมของผู้ใช้งานในช่วงเวลาหนึ่ง

**SWOT** คือเครื่องมือวิเคราะห์ที่ใช้ในการวางแผนกลยุทธ์สำหรับองค์กร ธุรกิจ หรือโครงการ โดยมุ่งเน้นการประเมินปัจจัยทั้งภายในและภายนอก เพื่อระบุจุดเด่น จุดด้อย โอกาส และภัยคุกคามที่ส่งผลต่อเป้าหมายขององค์กร

Strengths (S): จุดแข็ง สิ่งที่ดีองค์กรทำได้หรือมีความได้เปรียบ Weaknesses (W): จุดอ่อน ข้อจำกัดหรือปัญหาภายในที่ต้องปรับปรุง,Opportunities (O): โอกาส ปัจจัยภายนอกที่องค์กรสามารถใช้ให้เป็นประโยชน์ Threats (T): ภัยคุกคาม ปัจจัยภายนอกที่อาจสร้างปัญหา