

3.3 บทที่ 3 : Big Data Planning



Big Data Planning

8 - 9 กันยายน 2563

ผศ.ดร.สิริกร สันติโรจนกุล

อาจารย์ภูษิต ก้อนสุรินทร์

อาจารย์ ดร.เอกสิทธิ์ เทียมแก้ว

Digital Marketing Solution Providers Center

เพจ @digitalSPC




Topics

- Big Data Analytics Lifecycle
- Business Case Evaluation
- Data Identification
- Data Acquisition & Filtering
- Data Extraction
- Data Validation & Cleansing
- Data Aggregation & Representation
- Data Analysis
- Data Visualization

Traditional Data Mining Lifecycle


- CRISP-DM methodology
- Cross Industry Standard Process for Data Mining



Data Mining ?

- Database : ฐานข้อมูลที่ใช้ในการเก็บข้อมูล สามารถจัดเก็บ แก้ไข ปรับปรุงและลบข้อมูลได้
- Data warehouse : คลังข้อมูลที่เกิดจากการรวบรวมหลายๆ ฐานข้อมูลมีความเกี่ยวข้องกัน นำมาใช้ในการแสดงรายงาน
- Data Mining เป็นการวิเคราะห์ข้อมูลเพื่อค้นหาความสัมพันธ์ หรือ รูปแบบของข้อมูลที่เกี่ยวข้องกัน เพื่อนำมาใช้ให้เกิดประโยชน์ต่อองค์กร

ความสัมพันธ์



ความสัมพันธ์ของเหตุการณ์หรือวัตถุ
 ระบุประเภทของวัตถุจากคุณสมบัติขอ
 แบ่งข้อมูลที่มีลักษณะคล้ายกันออกเป็น
 สร้างแผนภาพ (Visualization)

ตัวอย่างการนำเอา Data Mining ไปใช้งาน

- ด้านการตลาด
 - การทำนายผลการตอบสนองกับการเปิดตัวสินค้าใหม่
 - การทำนายยอดขายเมื่อมีการลดราคาสินค้า
 - การทำนายกลุ่มลูกค้าที่น่าจะใช้สินค้าของเรา
- ด้านการเงินการธนาคาร
 - การคาดการณ์ถึงโอกาสในการชำระหนี้ของลูกค้าว่าสูงเท่าไร?
 - การค้นหาลูกค้าขาดคุณภาพ เพื่อหลีกเลี่ยงความเสี่ยงในการปล่อยกู้
 - การค้นหาลูกค้าชั้นดี เพื่อเสนอการปล่อยกู้
 - การทำนายแนวโน้มของพฤติกรรมการใช้บัตรเครดิต

ตัวอย่าง Data Mining


Classification Target

Attributes




Instances →

Name	Salary	Sex	Age	Buy widget
Bloggs	15000	male	19	No
Jones	25000	male	33	Yes
Smit	23000	female	50	No
Smit	16000	male	40	No
...				
Smit	200	male	10	No
Patel	30000	female	30	No
Steel	25000	male	23	Yes
Higgs	18000	female	55	No
Puggs	50000	male	57	Yes
Puggs	51000	female	57	No




ตัวอย่าง Data Mining : Market Basket Analysis

- เทคนิคในการค้นหากลุ่มสินค้าที่ซื้อร่วมกันในร้านค้า เป็นการวิเคราะห์ธุรกรรม โดยจะแสดงรูปแบบความสัมพันธ์ต่างๆ เช่น สินค้าที่ลูกค้าซื้อร่วมกันบ่อย ๆ เช่น ขนมปังและเนย หรือรายการใดที่มียอดขายสูงขึ้นในบางวันเช่น ยอดขายเบียร์ในวันศุกร์
- ข้อมูลนี้ช่วยในการวางแผนการจัดวางร้านค้าโดยเสนอส่วนลดพิเศษให้กับสินค้าที่มีความต้องการน้อยสร้างข้อเสนอเช่น “ซื้อ 2 แถม 1” หรือ “รับ 50% สำหรับการซื้อครั้งที่สอง” เป็นต้น




ตัวอย่าง Data Mining : Market Basket Analysis



Amazon กับ Data Mining

- ใช้เทคนิค Data Mining ไปประยุกต์ใช้กับงาน ได้แก่
- ระบบแนะนำหนังสือให้กับลูกค้า ข้อมูลการสั่งซื้อทั้งหมดจะถูกนำมาประมวลผลเพื่อหาความสัมพันธ์ของข้อมูล เช่น
- ลูกค้าที่ซื้อหนังสือเล่มหนึ่ง ๆ มักจะซื้อหนังสือเล่มใดพร้อมกันด้วยเสมอ ใช้ความสัมพันธ์ที่ได้จะสามารถนำไปใช้คาดเดาได้ว่าควรแนะนำหนังสือเล่มใดให้กับลูกค้าที่เพิ่งซื้อหนังสือจากร้าน
- Amazon เรียกว่า Product Recommendations ทำให้ได้ส่วนแบ่งจากการทำการแนะนำสินค้าแบบนี้กว่าร้อยละ 35 จากยอดขายทั้งหมด” (Siegel, 2013)

Amazon's Product Recommendations



Data Science for Marketing Analytics

ISBN-13: 978-1789959413
ISBN-10: 1789959411

More Buying Choices

Explore new and more sophisticated tools that will reduce your marketing analytics efforts and produce precise results

Key Features

- Study new techniques such as clustering and regression for marketing analytics
- Explore the applications of machine learning to power your marketing engines


Customers who bought this item also bought

- Predictive Marketing: Easy Ways Every Marketer Can Use Customer Analytics...** by Omer Artun (38 reviews)
- Marketing Data Science: Modeling Techniques in Predictive Analytics with...** by Miller Thomas W. (41 reviews)
- Data-Driven Marketing: The 15 Metrics Everyone in Marketing Should Know** by Mark Jeffery (112 reviews)
- Beyond The Prototype: A roadmap for navigating the fuzzy area between...** by Douglas Ferguson (58 reviews)
- Lean Analytics: Use Data to Build a Better Startup Faster** by Alistair Croll (223 reviews)
- Making Websites Win: Apply the Customer-Centric Methodology...** by Karl Blanks (150 reviews)
- Mining the Social Web: Data Mining Facebook, Twitter, LinkedIn,...** by Matthew A. Russell (11 reviews)

Traditional Data Mining Lifecycle

V.S.

Big Data Analytics Lifecycle



Big Data Analytics Lifecycle

Business Domain Tasks

1. Business
Case
Evaluation



2.Data
Identification



3.Data
Acquisition &
Filtering



4.Data
Extraction



5.Data
Validation &
Cleansing



9.Utilization
of Analysis
Results



8.Data
Visualization



7.Data
Analysis




6.Data
Aggregation &
Representation

Data Analyst Tasks

Business Case Evaluation (BCE)

- การประเมินธุรกิจ : เป็นการประเมินการดำเนินการในกรณีต่างๆของธุรกิจที่กำหนดไว้อย่างชัดเจน โดยสร้างความเข้าใจในธุรกิจก่อนการวิเคราะห์ข้อมูล ทำให้ทราบวิสัยทัศน์ พันธกิจ เป้าหมาย กลยุทธ์ กิจกรรม กระบวนการ ทรัพยากร ความท้าทาย ความเสี่ยง เป็นต้น

แนวทางในการทำ BCE



Big Data Analytics Project Understanding


- สร้างความเข้าใจในการทำโครงการวิเคราะห์ข้อมูล โดยจะต้องทราบในประเด็นต่อไปนี้
- เป้าหมายของโครงการ
 - วัตถุประสงค์
 - ตัวชี้วัด
- ขอบเขตและข้อจำกัดของโครงการ
- ทรัพยากรของโครงการ
 - ทรัพยากรบุคคล
 - เทคโนโลยี
 - งบประมาณ

วิเคราะห์กระบวนการทำงาน


- เป็นการวิเคราะห์กระบวนการทางกิจกรรมต่างๆ ที่สอดคล้องกัน โดยแบ่งออก 3 ส่วนคือ
 1. **ต้นน้ำ (Upstream)** แหล่งที่มาของวัตถุดิบ แหล่งทุน แรงงานมาจากไหน ซัพพลายเออร์ ผู้ผลิต หรือวัตถุดิบต่างๆ
 2. **กลางน้ำ (Midstream)** กระบวนการ การจัดการ การผลิต เพื่อให้เกิดสินค้า หรือ บริการ
 3. **ปลายน้ำ (Downstream)** กระบวนการ จัดเก็บ, ขนส่ง และ ส่งมอบสินค้าหรือ บริการนั้น ไปถึงมือลูกค้า ที่ต้องใช้สินค้าของเรา

Supply Chain หรือห่วงโซ่อุปทาน

- Material Flow
(การไหลของวัตถุดิบ)
- Information Flow
(การไหลของข้อมูล)
- Financial Flow
(การไหลของเงินทุน)



Supply Chain



วิเคราะห์ SWOT




“SWOT analysis is a powerful way to evaluate your company or project”

Strengths Weaknesses Opportunities Threats

(จุดแข็ง จุดอ่อน โอกาส อุปสรรค)

การวิเคราะห์จากปัจจัยภายใน-ภายนอกองค์กร



การสร้างกลยุทธ์ด้วย TOWS Matrix



ตัวอย่างการวิเคราะห์ SWOT ธุรกิจโรงแรม

จุดแข็ง (Strengths) • โรงแรมได้รับรางวัล Best Choice 9.8 คะแนน • โรงแรมตั้งอยู่ในทำเลที่ดีที่สุด ใกล้การคมนาคม และแหล่งท่องเที่ยว ช้อปปิ้ง • มีฐานลูกค้าเหนียวแน่น • มีห้องประชุม สัมมนา ที่ทันสมัย	จุดอ่อน (Weaknesses) • ไรท์ทำตลาดออนไลน์ • ลูกค้ารายใหม่มีน้อย • การจัดการระบบห้องประชุมสัมมนา ยังไม่เป็นระบบ ทำให้การให้บริการมีข้อบกพร่อง
โอกาส (Opportunities) • รัฐบาลมีนโยบายคูปองส่งเสริมการท่องเที่ยว สำหรับการท่องเที่ยวในประเทศ	อุปสรรค (Threats) • เกิดสถานการณ์ COVID-19 ทำให้ไม่มีลูกค้าจากนักท่องเที่ยวต่างชาติ • มีโรงแรมใหม่ๆ เกิดขึ้นจำนวนมาก • พฤติกรรมของลูกค้าเปลี่ยนไป

กลยุทธ์กลยุทธ์เชิงรุก (SO) ใช้จุดแข็ง+โอกาส

จุดแข็ง (Strengths)

- โรงแรมได้รับรางวัล Best Choice 9.8 คะแนน
- โรงแรมตั้งอยู่ในทำเลที่ดีที่สุด ใกล้การคมนาคม และแหล่งท่องเที่ยว ช้อปปิ้ง
- มีฐานลูกค้าเหนียวแน่น
- มีห้องประชุม สัมมนา ที่ทันสมัย

โอกาส(Opportunities)

- รัฐบาลมีนโยบายคุ้มครองส่งเสริมการท่องเที่ยว สำหรับการท่องเที่ยวในประเทศ

กลยุทธ์เชิงแก้ไข/พัฒนา (WO) ใช้โอกาสลดจุดอ่อน

จุดอ่อน (Weaknesses)

- การทำตลาดออนไลน์ไม่เก่ง
- ลูกค้ารายใหม่มีน้อย
- การจัดการระบบห้องประชุมสัมมนา ยังไม่เป็นระบบ
ทำให้การให้บริการมีข้อบกพร่อง

โอกาส (Opportunities)

- รัฐบาลมีนโยบายคูปองส่งเสริม
การท่องเที่ยว สำหรับการ
ท่องเที่ยวในประเทศ

กลยุทธ์เชิงรับ (ST) ใช้จุดแข็งรับมืออุปสรรค

จุดแข็ง (Strengths)

- โรงแรมได้รับรางวัล Best Choice 9.8 คะแนน
- โรงแรมตั้งอยู่ในทำเลที่ดีที่สุด ใกล้ การคมนาคม และแหล่งท่องเที่ยว ช้อปปิ้ง
- มีฐานลูกค้าเหนียวแน่น
- มีห้องประชุม สัมมนา ที่ทันสมัย

อุปสรรค (Threats)

- เกิดสถานการณ์ COVID-19 ทำให้ ไม่มีลูกค้าจากนักท่องเที่ยวต่างชาติ
- มีโรงแรมใหม่ๆ เกิดขึ้นจำนวนมาก
- พฤติกรรมของลูกค้าเปลี่ยนแปลงไป

กลยุทธ์เชิงป้องกัน (ถอย) (WT) แก้ไขจุดอ่อน+เลี้ยงอุปสรรค

จุดอ่อน (Weaknesses)

- การทำตลาดออนไลน์ไม่เก่ง
- ลูกค้านำใหม่มีน้อย
- การจัดการระบบห้องประชุมสัมมนา ยังไม่เป็นระบบ ทำให้การให้บริการมีข้อบกพร่อง

อุปสรรค (Threats)

- เกิดสถานการณ์ COVID-19 ทำให้ไม่มีลูกค้าจากนักท่องเที่ยวต่างชาติ
- มีโรงแรมใหม่ๆเกิดขึ้นจำนวนมาก
- พฤติกรรมของลูกค้าเปลี่ยนไป

Data Identification

External Data Source



Data
Identification



- Business Scope
- Business problem
- Business Case Evaluation



Internal Data Source

Data
Identification

- Business Scope
- Business problem
- Business Case Evaluation



Datasets




Next
Process

Data Acquisition & Filtering

- ข้อมูลจะถูกรวบรวมจากแหล่งข้อมูลทั้งหมดที่ระบุในขั้นตอนก่อนหน้านี้ จากนั้นข้อมูลที่ได้มาจะถูกกรองโดยอัตโนมัติ
- การกรองข้อมูลที่เสียหายหรือข้อมูลที่ไม่มีคุณค่าในการวิเคราะห์ออกไป



Data Acquisition & Filtering



Data Extraction

- ข้อมูลบางส่วนที่ระบุว่าเป็นอินพุตสำหรับการวิเคราะห์อาจอยู่ในรูปแบบที่ไม่สอดคล้องกับโซลูชันของ Big Data
- ดังนั้นมีความจำเป็นอย่างยิ่งในการระบุประเภทของข้อมูลที่แตกต่างกันเมื่อต้องใช้ข้อมูลจากแหล่งภายนอก
- จึงต้องใช้การสกัดข้อมูลเพื่อแยกข้อมูลที่แตกต่างกันและแปลงเป็นรูปแบบที่สามารถนำมาใช้ในการวิเคราะห์ข้อมูล




Data Extraction

Extract

Load

Transform


Analyze



Data Extraction Software




Extract



Load

Transform



Analyze



Extracting XML data into a Structured data (table)

```


1 <?xml version="1.0"?>
2 <catalog>
3   <book id="bk101">
4     <author>Gambardella, Matthew</author>
5     <title>XML Developer's Guide</title>
6     <genre>Computer</genre>
7     <price>44.95</price>
8     <publish_date>2000-10-01</publish_date>
9     <description>An in-depth look at creating applications
10    with XML.</description>
11   </book>
12   <book id="bk102">
13     <author>Ralls, Kim</author>
14     <title>Midnight Rain</title>
15     <genre>Fantasy</genre>
16     <price>5.95</price>
17     <publish_date>2000-12-16</publish_date>
18     <description>A former architect battles corporate zombies,
19     an evil sorceress, and her own childhood to become queen
20     of the world.</description>
21   </book>
22   <book id="bk103">
23     <author>Corets, Eva</author>
24     <title>Maeve Ascendant</title>
25     <genre>Fantasy</genre>

```



book_id	author	title	genre	price	publish_date	description
bk101	Gambardella, Matthew	XML Developer's Guide	Computer	44.95	2000-10-01	An in-depth look at cr
bk102	Ralls, Kim	Midnight Rain	Fantasy	5.95	2000-12-16	A former architect bat
bk103	Corets, Eva	Maeve Ascendant	Fantasy	5.95	2000-11-17	After the collapse of a
bk104	Corets, Eva	Oberon's Legacy	Fantasy	5.95	2001-03-10	In post-apocalypse En
bk105	Corets, Eva	The Sundered Grail	Fantasy	5.95	2001-09-10	The two daughters of

Extracting JSON data into a Structured data (table)



Web Scrapping




Data Validation & Cleansing

- Big Data มักจะมีการซ้ำซ้อนในชุดข้อมูลต่างๆ ความซ้ำซ้อนนี้สามารถใช้เพื่อสำรวจชุดข้อมูลที่เชื่อมต่อกันเพื่อประกอบพารามิเตอร์การตรวจสอบความถูกต้องและกรอกข้อมูลที่ถูกต้องที่ขาดหายไป
- ข้อมูลที่ไม่ถูกต้องอาจทำให้ผลการวิเคราะห์ผิดพลาดได้

Data Validation?

- “การตรวจสอบข้อมูล”
- เป็นส่วนสำคัญของงานจัดการข้อมูล ทั้งการรวบรวมข้อมูล การวิเคราะห์ข้อมูลหรือการเตรียมข้อมูลเพื่อนำเสนอข้อมูล




แนวทางของ Data Validation

167

- แนวทางที่ใช้ในการตรวจสอบความถูกต้องของข้อมูลคือแนวทางที่รับประกันความถูกต้องและความสมบูรณ์ของข้อมูล เช่น ตรวจสอบการสะกด การตรวจสอบข้อมูล. ความยาวรหัสผ่านขั้นต่ำ? การตรวจสอบข้อมูล เป็นต้น
- แต่ละองค์กรที่ใช้ข้อมูลจะต้องมีแนวทางของตนเองในการตรวจสอบข้อมูลเพื่อใช้งานข้อมูลอย่างมีประสิทธิภาพ ได้แก่
- ตรวจสอบชนิดข้อมูล (Data type) เช่น integer, float, string
- ตรวจสอบช่วงของข้อมูล (Range เช่น ช่วงอายุ ระหว่าง 35-40)
- ตรวจสอบข้อมูลเอกลักษณ์ (Uniqueness เช่น รหัสบุคลากร รหัสไปรษณีย์)
- ตรวจสอบความสอดคล้องของข้อมูล (Consistent expressions เช่น ชม. แทนเชียงใหม่)
- ตรวจสอบข้อมูลต้องไม่มีค่าว่าง (No null values)

Data Validation ด้วย Excel


- Ribbon Data => Data Validation => Data Validation...



Data Validation ด้วย Excel


169

- Ribbon Data => Data Validation => Data Validation...



Data Cleansing?

- Data cleansing หรือ data cleaning หรือ data scrubbing เป็น การทำความสะอาดข้อมูล เป็นกระบวนการตรวจสอบและการแก้ไข (หรือลบ) รายการข้อมูลที่ไม่ถูกต้องออกไปจากชุดข้อมูล



Data Aggregation & Representation

- เป็นกระบวนการรวบรวมข้อมูลและนำเสนอในรูปแบบสรุป
- เป็นขั้นตอนที่สำคัญเนื่องจากความแม่นยำของข้อมูลเชิงลึกที่ได้จากการวิเคราะห์ข้อมูลขึ้นอยู่กับปริมาณและคุณภาพของข้อมูลที่ใช้
- ข้อมูลอาจถูกรวบรวมจากหลายแหล่งเพื่อจุดประสงค์ในการรวมแหล่งข้อมูลเหล่านี้เป็นสรุปสำหรับการวิเคราะห์ข้อมูล
- ประโยชน์สำหรับทุกอย่างตั้งแต่การตัดสินใจทางการเงินหรือกลยุทธ์ทางธุรกิจไปจนถึงการกำหนดราคาผลิตภัณฑ์การดำเนินงานและกลยุทธ์ทางการตลาด

ตัวอย่าง Data Aggregation

Location	Bear	Date	Quantity
Canada	Polar Bear	11/4/1982 12:00:00 AM	5.00
Canada	Brown Bear	1/6/1990 12:00:00 AM	10.00
USA	Black Bear	1/6/1990 12:00:00 AM	15.00
USA	Polar Bear	3/2/1990 12:00:00 AM	20.00
Mexico	Grizzly Bear	8/4/2018 12:00:00 AM	25.00


Location	Bear	Date	Quantity
Canada	Brown Bear	1/6/1990 12:00:00 AM	10.00
Canada	Polar Bear	11/4/1982 12:00:00 AM	5.00
Mexico	Grizzly Bear	8/4/2018 12:00:00 AM	25.00
USA	Black Bear	1/6/1990 12:00:00 AM	15.00
USA	Polar Bear	3/2/1990 12:00:00 AM	20.00



Location
Canada
Mexico
USA

Location	Bear	Date	Quantity		Location	Bear
Canada	Brown Bear	1/6/1990 12:00:00 AM	10.00		Canada	Brown Bear
Canada	Polar Bear	11/4/1982 12:00:00 AM	5.00			Polar Bear
Mexico	Grizzly Bear	8/4/2018 12:00:00 AM	25.00		Mexico	Grizzly Bear
USA	Black Bear	1/6/1990 12:00:00 AM	15.00		USA	Black Bear
USA	Polar Bear	3/2/1990 12:00:00 AM	20.00			Polar Bear

Data Visualization



What is Data Visualization?

- การสร้างภาพข้อมูล (Data Visualization) คือการสร้างและศึกษาการแสดงภาพข้อมูล บางครั้งเรียกว่าการสื่อสารด้วยภาพหรือสถิติเชิงพรรณนาและรวมถึงเทคนิคในการนำเสนอข้อมูลในลักษณะที่เป็นภาพเพื่อการสื่อสารข้อมูลที่ชัดเจนและกระตุ้นการมีส่วนร่วมและความสนใจของผู้ชม
- การทำ Data Visualization แล้ว อาจทำให้เราไม่สามารถค้นพบนัยยะของข้อมูลในแง่ของแนวโน้ม, รูปแบบพฤติกรรม, และความสัมพันธ์เชื่อมโยงได้

ลักษณะของ Data Visualization

- **ใช้งานง่าย (Intuitive)** : เนื่องจากการนำเสนอภาพข้อมูล สามารถสื่อสารภาพได้เข้าใจได้ทันทีทำให้รู้สึกถึงแม้กับคนที่ไม่เคยทำงานกับกราฟมาก่อน
- **เข้าใจได้รวดเร็ว (Fast)** : ด้วยการสร้างภาพ ทำให้สามารถมองเห็นแนวโน้มและข้อมูลต่างๆ ได้อย่างมีประสิทธิภาพ
- **ความยืดหยุ่น (Flexible)** : มีความยืดหยุ่น ตามลักษณะของข้อมูล
- **ข้อมูลเชิงลึก (Insightful)** : มีความชาญฉลาด: ภาพข้อมูลจะช่วยให้ผู้ที่จะได้รับความรู้เพิ่มเติมในเชิงลึกเข้าใจบริบทและถามคำถามมากขึ้นเมื่อเทียบกับการสร้างภาพแบบคงที่หรือข้อมูลดิบ


ปัจจัยประสิทธิผลในการทำ Visualization

- **Visual cues / Visual encoding:** การแปลงข้อมูลให้แสดงในลักษณะของรูปร่าง, สี, หรือขนาด
- **Coordinate systems:** หมายถึงระบบพิกัดที่ช่วยทำให้เกิดพื้นที่ที่มีโครงสร้าง สำหรับใส่ข้อมูลที่ต้องการแสดง รูปแบบพื้นฐานที่เราเห็นได้ทั่วไปคือ ระบบพิกัดที่มีแกน X แกน


ปัจจัยประสิทธิผลในการทำ Visualization

- **Scale / Data types:** จะต้องสอดคล้องกับระบบพิกัดข้างต้น โดย Data types พื้นฐานนั้นมีอยู่ 3 ประเภทได้แก่ ข้อมูลเชิงตัวเลข (Numeric), ข้อมูลที่เป็นหมวดหมู่ (Categorical), และ
- **Context:** ในกรณีที่ผู้รับสารไม่คุ้นเคยกับข้อมูล เป็นหน้าที่ของ Data Scientist ที่จะต้องระบุบริบทของข้อมูลให้ชัดเจน และอธิบายว่าควรจะอ่านข้อมูลจากกราฟอย่างไร อย่างเช่น การตั้งชื่อกราฟ, ระบุแกน X แกน Y ว่าคืออะไร, หรือการระบุเหตุการณ์บางอย่างที่สำคัญลงบนแกนลำดับเวลา เพื่อให้ผู้อ่านสามารถตีความและเข้าใจได้มากขึ้นข้อมูลตามลำดับเวลา (Time Series)


Visual Encoding



Position



Length



Angle

Visual Encoding

- **Position:** การระบุตำแหน่งของข้อมูลแต่ละจุด ทำให้สามารถเปรียบเทียบข้อมูลแต่ละจุดได้บนระบบพิกัด (Coordinate System) เดียวกัน การแปลงข้อมูลให้อยู่ในรูปแบบของตำแหน่งนั้นใช้พื้นที่น้อยเมื่อเทียบกับการเข้ารหัสข้อมูลแบบอื่น ๆ และเนื่องด้วยที่จุดแต่ละจุดมีขนาดเท่ากัน ทำให้สามารถสังเกตเห็นแนวโน้ม (Trend), การเกาะกลุ่ม (Cluster), หรือจุดที่แปลกแยก (Outlier) ของข้อมูลได้ง่าย อย่างไรก็ตาม หากมีจุดข้อมูลมากเกินไปอาจทำให้ไม่สามารถเข้าใจความหมายของแต่ละจุดได้
- **Length:** การเข้ารหัสข้อมูลพื้นฐานอีกแบบหนึ่งคือการใช้ความยาว ซึ่งมักจะเห็นได้ในรูปแบบของกราฟแท่ง ความยาวของกราฟแท่งระบุปริมาณของข้อมูล

Visual Encoding

- **Angle:** รูปแบบนี้ก็สามารถพบเห็นได้ทั่วไปเช่นเดียวกัน ตัวอย่างที่เห็นได้ชัดก็คือ กราฟวงกลมหรือ Pie Chart นั่นเอง ข้อมูลจะอยู่ในช่วงของมุม 0 - 360 องศา ซึ่งวิธีนี้จะถูกใช้แสดงข้อมูลในแง่ของอัตราส่วน แต่ข้อเสียอย่างหนึ่งของรูปแบบนี้คือ การสังเกตเห็นความแตกต่างของมุมนั้นทำได้ยากจากการมองด้วยตา เช่น เราอาจไม่สามารถสังเกตเห็นความแตกต่างระหว่างมุม 25 องศา กับมุม 30 องศาได้เลย ดังนั้น จึงควรหลีกเลี่ยงวิธีนี้หากต้องการแสดงความแตกต่างเล็กน้อยของข้อมูล

Visual Encoding



Direction



Shape


Area / Volume

Visual Encoding

- **Direction:** การใช้ทิศทาง จะทำให้สามารถสังเกตความชันและรู้ได้อย่างง่ายดายว่า ข้อมูลมีการเพิ่มขึ้น ลดลง หรือมีความผันผวนอย่างไร การเข้ารหัสข้อมูลโดยใช้ทิศทางมีความคล้ายกับการใช้มุม (Angle) โดยเป็นไปได้ยากที่จะแยกความแตกต่างระหว่างเส้นที่มีความชันใกล้เคียงกัน
- **Shape:** รูปร่างหรือสัญลักษณ์สามารถใช้ในการจัดหมวดหมู่ให้กับข้อมูล หรือแยกข้อมูล 2 ชุดเพื่อเปรียบเทียบกันได้
- **Area / Volume:** เรายังสามารถใช้พื้นที่ หรือขนาดในการเข้ารหัสข้อมูลได้ ขนาดที่ใหญ่กว่าแสดงถึงค่าที่มากกว่า

Visual Encoding

- **Color:** เราสามารถเข้ารหัสข้อมูลโดยใช้สีได้ ซึ่งสามารถใช้ได้ทั้ง Hue และ Saturation โดยสามารถใช้อันใดอันหนึ่งหรือใช้ทั้งคู่ประกอบกันก็ได้



Data Types: ประเภทข้อมูลพื้นฐาน

- **Numeric:** ใช้ในการแสดงข้อมูลเชิงปริมาณ (Quantitative) อย่างใดอย่างหนึ่ง อาจจะเป็นความสูง, น้ำหนัก, หรือการนับจำนวนโฮมรัน โดยเป็นได้ทั้ง Discrete และ Continuous ตัวอย่างเช่น จำนวนโฮมรันนับเป็น Discrete เพราะแสดงจำนวนตัวเลขนั้น ๆ โดยเฉพาะ (10, 34, 25) แต่อัตราการตีได้ (Hit Rate) นับเป็น Continuous เพราะแทนค่าตัวเลขในช่วงนั้น ๆ (.250, .357, .511)

Data Types: ประเภทข้อมูลพื้นฐาน

- **Categorical:** ใช้ในการแสดงข้อมูลคุณลักษณะ เช่น ตำแหน่งการเล่นในทีมเบสบอล, ทีมเบสบอลที่สังกัด, บ้านเกิด, มือข้างที่ถนัด เป็นต้น มีข้อมูลประเภทหนึ่งที่ถูกเรียกว่า Ordinal Data ซึ่งเหมือนการผสมระหว่าง Numeric และ Categorical แต่ถูกจัดไว้ในประเภทของ Categorical Data หมายถึงข้อมูลที่มีลำดับอย่างใดอย่างหนึ่ง ตัวอย่างของข้อมูลประเภทนี้ ได้แก่ ความแรงในการตีลูกเบสบอลอาจเรียงได้จาก Very Low > Low > Average > High > Very High หรือการให้คะแนนภาพยนตร์เรื่องหนึ่งๆ ตั้งแต่ 1 ดาว ไปจนถึง 5 ดาว

Data Types: ประเภทข้อมูลพื้นฐาน

- **Time Series:** หมายถึงข้อมูลที่ถูกเก็บตามลำดับเวลา อย่างเช่น การเก็บข้อมูลจำนวนโฮมรันที่เกิดขึ้นในแต่ละปี จะเห็นได้ว่าจริง ๆ แล้วข้อมูลที่เก็บนับเป็น Numeric Data แต่การเก็บข้อมูลตามลำดับเวลาทำให้ข้อมูลเหล่านั้นเกิดลำดับขึ้นมาอย่างหนึ่ง ซึ่งนั่นก็คือ ลำดับเวลา

ชนิดของ Visualizations



1. Temporal
2. Hierarchical
3. Network
4. Multidimensional
5. Geospatial

Temporal


- การสร้างภาพเชิงเวลา (หรือไทม์ไลน์) คล้ายกับการสร้างภาพข้อมูลเชิงเส้นแบบหนึ่งมิติ เนื่องจากไทม์ไลน์มีการใช้กันอย่างแพร่หลายและมีความสำคัญ เช่น ข้อมูลเวชระเบียน การจัดการโครงการ และการนำเสนอข้อมูลในอดีต ถือว่าเป็นประเภทข้อมูลแยก
- ข้อมูลเชิงเวลามีลักษณะรายการที่มีเวลาเริ่มต้นและสิ้นสุดและรายการอาจทับซ้อนกัน การแสดงข้อมูลเส้นเวลามักจะรวมเหตุการณ์ทั้งหมดก่อนหลังหรือระหว่างช่วงเวลาหรือช่วงเวลา
- เช่น
 - Scatter plots
 - Polar area diagrams
 - Time series sequences
 - Timelines
 - Line graphs

Scatter plots




- แผนภาพกระจาย(scatter plot) จะใช้แสดงภาพตัวแปรสองตัว พร้อมกัน เช่น อาจจะศึกษาความสัมพันธ์ของตัวแปรสองตัว หรือสามตัว ข้อมูลที่เราได้จากการศึกษาก็จะมีสองข้อมูล (Rivariate data)



Correlation Strength:





Polar area diagrams



Handwritten signature

Time series sequences




Timelines


Sequential Timeline:



Scaled Timeline:





Timelines



Line graphs


Value Scale






Hierarchical

- การสร้างภาพข้อมูล ประเภทลำดับชั้น (Hierarchical) จะใช้กับข้อมูลที่สามารถจัดเรียงในรูปแบบของต้นไม้ ข้อมูลแต่ละรายการจะกำหนดโหนดในทรีและแต่ละโหนดอาจมีการรวบรวมโหนดอื่น ๆ เป็นโหนดย่อย ความสัมพันธ์ระหว่างโหนดพารেন্টและโหนดย่อยเป็นเครือข่ายแบบต้นไม้
- เป็นเทคนิคการสร้างภาพข้อมูลสำหรับชุดข้อมูลที่มีลำดับชั้นขนาดใหญ่ มักจะเลือกใช้แผนภาพต้นไม้ (Treemap) เนื่องจากเป็นวิธีที่ง่ายที่สุดในการติดตามจากเส้นทางเชิงเส้น
- เช่น
 - Tree diagrams (Treemap)
 - Ring charts
 - Sunburst diagrams
- ข้อด้อยของกราฟเหล่านี้คือพวกเขามักจะมีความซับซ้อนและอ่านยาก



Hierarchical





Tree diagrams (Treemap)



Ring charts /Donut Chart



Sunburst diagrams





● USA
 ● India
 ● Germany
 ● UK
 ● France





Network Data Visualization

- เป็นกระบวนการของการนำเสนอเครือข่ายที่เชื่อมต่อการมองเห็นเป็นลิงค์และโหนด




Multidimensional



- Multidimensional จะสัมพันธ์กับมิติของตัวแปรข้อมูลที่เราสนใจ เช่น 3 ตัวแปร ก็จะใช้ภาพแบบ 3 มิติ
- เช่น
 - Scatter plots
 - Pie charts
 - Venn diagrams
 - Stacked bar graphs
 - Histograms




Scatter plots Multidimensional





Pie charts Multidimensional (Multilevel)



Venn diagrams Multidimensional





Stacked bar graphs Multidimensional




Histograms Multidimensional

208





Geospatial


- การสร้างภาพข้อมูลเชิงพื้นที่ จะเกี่ยวข้องกับสถานที่ทางกายภาพในชีวิตจริงซ้อนทับแผนที่ โดยมีจุดข้อมูลที่แตกต่างกัน
- การแสดงข้อมูลด้วยภาพเหล่านี้มักใช้เพื่อแสดงยอดขายหรือการได้มาในช่วงเวลาหนึ่งและสามารถเป็นที่รู้จักมากที่สุดสำหรับการใช้ในแคมเปญทางการเมืองหรือเพื่อแสดงส่วนแบ่งการตลาดใน บริษัท ข้ามชาติ เป็นต้น
- เช่น
 - Flow map
 - Density map
 - Cartogram
 - Heat map



Flow map




Density map



Cartogram


การนำเสนอข้อมูลสถิติในรูปแบบของแผนที่ซึ่งสามารถเปลี่ยนแปลงรูปทรงหรือพื้นที่ว่างได้ เพื่อที่จะแสดงให้เห็นความแปรปรวนของข้อมูล นำเสนอโดยใช้ค่าทางสถิติ เช่น เวลาที่ใช้ในการเดินทาง จำนวนประชากร หรือผลิตภัณฑ์มวลรวมประชาชาติ (Gross national product: GNP) ซึ่งแทนที่ด้วยขนาดพื้นที่ หรือระยะความห่าง





Heat map

- การแสดงภาพของข้อมูล โดยจะแสดงออกมาในรูปแบบของ “ สี ” ซึ่งแต่ละสีจะบ่งบอกถึงระดับความถี่ บ่อย ของพฤติกรรม หรือข้อมูลที่น่าสนใจอื่นๆ
- อาจจะมีการนำเอาแผนที่มาใช้ร่วมกับการวิเคราะห์ข้อมูลทางประชากรศาสตร์ (Demographic data) อาทิ ตำแหน่งสถานที่สำคัญ และนำมาผ่านกระบวนการวิเคราะห์ เพื่อนำผลการวิเคราะห์นั้น มาประกอบการตัดสินใจในการดำเนินธุรกิจ การวางกลยุทธ์ขององค์กรในด้านต่างๆ ไม่ว่าจะเป็นการขยายธุรกิจ การใช้เครื่องมือทางการตลาด และการวิเคราะห์ความสามารถของบริษัทฯ ในการเข้าถึงกลุ่มลูกค้าเป้าหมาย ผลการวิเคราะห์นี้สามารถนำไปประยุกต์ใช้ได้กับลูกค้าหลากหลายธุรกิจที่ไม่ว่าจะเป็น ร้านสะดวกซื้อ, สถาบันการเงิน, บริษัทโฆษณาทำการตลาด,

Heat map





Heat map





Choropleths

- แผนที่โครเพลท (Choropleth Map) เป็นแผนที่ที่ใช้แสดงความแตกต่างของข้อมูลด้วยสีหรือความอ่อนเข้มของสี หรือลวดลายในสัดส่วนที่เป็นตัววัดของตัวแปรทางสถิติที่มี การแสดงบนแผนที่ เช่น ความหนาแน่นของประชากรแผนที่โครเพลทอยู่ในประเภทของแผนที่เฉพาะเรื่องเพราะเป็นแผนที่ที่แสดงเฉพาะสิ่งที่สนใจในบริเวณพื้นที่ภูมิศาสตร์ที่สนใจเท่านั้น

Choropleths



Graduated Circles/ Bubble Map




คุณค่าของการแสดงภาพข้อมูล (The Value of Visualization)

- การสร้างภาพข้อมูลเป็นวิธีการหนึ่งที่ทำให้ผู้ใช้สามารถได้รับข้อมูลเชิงลึกของประเด็นที่สนใจ ซึ่งการแสดงผลข้อมูลในรูปแบบของตารางต้องใช้เวลาในการทำ ความเข้าใจค่อนข้างนานและเข้าใจยาก ดังนั้นคุณค่าของการแสดงภาพข้อมูลสามารถจำแนกได้ดังนี้
 1. การสร้างภาพข้อมูลช่วยให้ผู้ชมทำความเข้าใจชุดข้อมูลขนาดใหญ่ได้ง่ายขึ้น
 2. การสร้างภาพข้อมูลช่วยให้ผู้ใช้เข้าใจข้อมูลในระดับที่ใช้งานง่ายขึ้น
 3. การสร้างภาพข้อมูลช่วยให้ผู้ใช้เห็นความสัมพันธ์ระหว่างชุดข้อมูล
 4. การสร้างภาพข้อมูลสามารถช่วยเปลี่ยนมุมมองหรือพฤติกรรมของเราได้

1. การสร้างภาพข้อมูลช่วยให้ทำความเข้าใจชุดข้อมูลขนาดใหญ่ได้ง่ายขึ้น

ข้อมูลจำนวนมากจะถูกเก็บรวบรวมจัดเรียงและนำเสนอในการสร้างภาพข้อมูล โดยช่วยในการบอกเล่าเรื่องราวและให้ผู้ชมภาพรวมของสิ่งที่ข้อมูลที่จะบอกเรา



ภาพนี้เป็นรายงานประจำปี 2012 ของ
บ. Lemonly โดยสามารถดูได้ทันทีว่า
เดือนใดที่มีจำนวนการดูหน้าเว็บมากที่สุด
- พฤษภาคมและกุมภาพันธ์

2. การสร้างภาพข้อมูลช่วยให้ผู้ใช้เข้าใจข้อมูลในระดับที่ใช้งานง่ายขึ้น

เนื่องจากการสร้างภาพข้อมูลช่วยให้เราสามารถมุ่งเน้นไปที่ข้อมูลที่เกี่ยวข้องและมีความสำคัญซึ่งแสดงถึงข้อมูลเพื่อให้เราเข้าใจได้ทันทีว่าเกิดอะไรขึ้น




จากภาพจะเห็นข้อมูลสองระดับชั้น โดยมี การใช้สีเน้นสิ่งที่จะมุ่งเน้น เพื่อแสดงว่า

1. ผู้เล่น MLS มาจากประเทศใด
2. และจำนวนผู้เล่นจากแต่ละประเทศ

3. การสร้างภาพข้อมูลช่วยให้ผู้ใช้เห็นความสัมพันธ์ระหว่างชุดข้อมูล


ผู้ใช้สามารถทำการเชื่อมโยงและสามารถระบุรูปแบบข้อมูล ซึ่งจะไม่สามารถทำได้ในข้อมูลแบบปกติ



ภาพนี้แสดงถึง จำนวนคนของแต่ละประเทศด้วยขนาดของกราฟวงกลมในขณะที่ใช้สิ่ระบบประเภทความแตกต่างของ ลูกค้า 3 กลุ่ม โดยเราสามารถสังเกตเห็นความสัมพันธ์ที่แตกต่างกันหลายประการในข้อมูล เช่น - มีผู้ใช้ร่วมกันในสหรัฐอเมริกามากกว่าแคนาดาและสหราชอาณาจักร

4. การสร้างภาพข้อมูลสามารถช่วยเปลี่ยนมุมมองหรือพฤติกรรมของเราได้

เนื่องจากจะสามารถเข้าใจข้อมูลได้ชัดเจนยิ่งขึ้นเมื่อมีการแสดงข้อมูลเป็นภาพ และสามารถช่วยเราตัดสินใจได้อย่างชาญฉลาดมากขึ้น



- จากภาพเราสามารถดูปริมาณการใช้ไฟฟ้า เมื่อเทียบกับบ้านใกล้เคียงที่คล้ายกัน เนื่องจากมีบริบทของว่าได้ใช้ไฟฟ้ามากกว่าเมื่อเทียบกับคนอื่น ๆ ในละแวกบ้าน
- เมื่อผู้ใช้อินโฟร์เมชันเปลี่ยนแปลงพฤติกรรมเพื่อ