

บทที่ 1 : Understanding Big Data

Big Data คือ การใช้ประโยชน์จากกระบวนการรวบรวม การจัดเก็บ การประมวลผล และการวิเคราะห์ข้อมูล **Datasets** : ชุดข้อมูลหรือกลุ่มข้อมูลที่เกี่ยวข้องกัน ซึ่งอาจจะอยู่ในหลากหลายรูปแบบ เช่น ไฟล์ข้อมูล รูปภาพ ตารางข้อมูล

Big Data Terminology

Data Analysis หรือการวิเคราะห์ข้อมูล เป็นกระบวนการตรวจสอบข้อมูลเพื่อค้นหาข้อเท็จจริง ความสัมพันธ์รูปแบบข้อมูลเชิงลึกและ/หรือแนวโน้ม

การวิเคราะห์เชิงพรรณนา (Descriptive Analytics) คือ การใช้ข้อมูลเพื่ออธิบายเหตุการณ์ในอดีต เช่น รายงาน ธุรกิจ รายงานผลโฆษณา หรือผลการดำเนินงาน ช่วยให้เข้าใจภาพรวมและใช้เป็นพื้นฐานสำหรับการวิเคราะห์ขั้นสูงในอนาคต

การวิเคราะห์เชิงวินิจฉัย (Diagnostic Analytics) คือ การวิเคราะห์หาสาเหตุของเหตุการณ์ โดยเปรียบเทียบข้อมูลในอดีตกับข้อมูลอื่น ๆ เพื่อระบุปัจจัยที่เกี่ยวข้องต้องอาศัยข้อมูลที่ละเอียดเพียงพอเพื่อความแม่นยำ

การวิเคราะห์เชิงพยากรณ์ (Predictive Analytics) คือ การใช้ข้อมูลและโมเดลคณิตศาสตร์เพื่อทำนายแนวโน้มโอกาสและความเสี่ยงในอนาคต.

การวิเคราะห์เชิงกำหนด (Prescriptive Analytics) คือ การทำนายพร้อมแนะนำทางเลือกและข้อดี-ข้อเสีย โดยใช้ Big Data.

Business Intelligence (BI) คือกระบวนการใช้เทคโนโลยีวิเคราะห์และนำเสนอข้อมูล เพื่อช่วยในการตัดสินใจทางธุรกิจอย่างมีข้อมูล.

Characteristics of Big Data 3Vs

ปริมาณข้อมูลขนาดใหญ่ Volume , ความรวดเร็วในการประมวลผล Velocity , ความหลากหลายของกลุ่มข้อมูล Variety

5Vs คุณค่าของข้อมูล Value , ปริมาณข้อมูลขนาดใหญ่ Volume , ความหลากหลายของกลุ่มข้อมูล Variety , คุณภาพหรือความน่าเชื่อถือ ของข้อมูล Veracity , ความรวดเร็วในการประมวลผล Velocity

Types of Data

Human-generated data แหล่งสร้างข้อมูล เช่น โซเชียล มีเดีย อีเมล

Machine-generated data แหล่งข้อมูลจาก web logs ข้อมูลจากเซ็นเซอร์ข้อมูล จากเครื่องใช้ตู้เย็น Smart meter

Structured Data Example E-Commerce ประกอบด้วย Product Catalog Systems , Member System , Shopping Cart

Unstructured Data Example video , image files , audio

Semi-structured Data Example E-mails, XML and other markup

Big Data Ecosystem คือกระบวนการรวบรวม ประมวลผล เผยแพร่ และรายงานข้อมูล โดยใช้โครงสร้างพื้นฐานและเครื่องมือในการจัดการข้อมูล Ingest: การจัดเก็บและรวบรวมข้อมูล , Process: การประมวลผลข้อมูล , Publish: การเผยแพร่ข้อมูล , Report: การรายงานผลข้อมูล

เทคโนโลยีสำหรับ Big Data มี ฐานข้อมูล RDBMS , Hadoop HDFS

บุคลากรในการจัดการข้อมูลขนาดใหญ่ประกอบด้วย 3 กลุ่มหลัก

Data System Data Engineer ออกแบบระบบข้อมูล

Data Modeling Data Scientist ออกแบบ Model

Data Communication Data Analyst ใช้ผลของ Model และสื่อสาร

Infrastructure เป็นสิ่งสำคัญในการจัดการข้อมูลขนาดใหญ่ เพื่อรองรับการประมวลผลและจัดเก็บข้อมูลที่มีความหลากหลาย โดยต้องใช้เทคโนโลยีใหม่แทนฐานข้อมูลเชิงสัมพันธ์ที่ไม่สามารถรองรับข้อมูลขนาดใหญ่ได้.

Analytics/Process รวมถึงเทคโนโลยีที่ออกแบบมาเพื่อการวิเคราะห์ข้อมูล โดยจะมีส่วนย่อยของงานในส่วนนี้ดังนี้

Analytics Platforms: รวบรวมและวิเคราะห์ข้อมูลเพื่อสร้างรายงานที่ช่วยในการตัดสินใจ

Visualization Platform: ออกแบบการนำเสนอข้อมูลดิบในรูปแบบที่ซับซ้อนเพื่อการอธิบาย

Business Intelligence (BI) Platforms: วิเคราะห์ข้อมูลทางธุรกิจจากหลายแหล่งเพื่อสร้างรายงานและแดชบอร์ด

Machine Learning: การเรียนรู้จากข้อมูลเพื่อค้นหาความสัมพันธ์และตอบคำถามต่าง ๆ ด้วยตัวเอง.

บุคลากรในการจัดการข้อมูลขนาดใหญ่ประกอบด้วย 3 ผู้เชี่ยวชาญหลัก:

Data System: Data Engineer ออกแบบระบบการไหลของข้อมูล การจัดเก็บ และช่องทางการนำผลลัพธ์ไปแสดงผล

Data Modeling: Data Scientist สร้างแบบจำลอง (Model) ที่เหมาะสมจากข้อมูลขนาดใหญ่ และค้นหาผลลัพธ์เชิงลึก (Insight)

Data Communication: Data Analyst ใช้ข้อมูลจาก Model ไปใช้งานและสื่อสารผลลัพธ์ พร้อมประเมินปัญหาและผลลัพธ์จาก Model.

Career Path ของ Data Expert:

Data Engineer → Chief Technology Officer (CTO) หรือผู้บริหารระดับสูงด้านเทคโนโลยี

Data Scientist → Specialist → Chief Information Officer (CIO) หรือผู้บริหารเทคโนโลยีสารสนเทศระดับสูง

Data Analyst → Business Analyst → Chief Marketing Officer (CMO) หรือ Chief Financial Officer (CFO) หรือ Chief Operating Officer (COO) หรือ Chief Executive Officer (CEO)

ETL (Extract, Transform, Load) คือกระบวนการนำข้อมูลจากแหล่งต่าง ๆ เช่น Marketing, Sales, Customer Service มาทำการแปลงรูปแบบแล้วเก็บใน Data Warehouse หรือ Data Lake เพื่อใช้งานในการวิเคราะห์หรือทำ Dashboard สำหรับผู้บริหาร.

Scaling Out คือการขยายระบบโดยการเพิ่มเซิร์ฟเวอร์ขนาดเล็กหลายตัวเพื่อกระจายภาระการประมวลผล แทนการขยายระบบใหญ่ (Scaling Up) โดยการใช้เครือข่ายพื้นที่เก็บข้อมูล (SAN) และเซิร์ฟเวอร์ SQL ในการค้นหาข้อมูล.

องค์ประกอบของ Big Data (6V):

1. **Volume (ปริมาณ):** ข้อมูลจำนวนมากที่สามารถนำมาวิเคราะห์
2. **Variety (ความหลากหลาย):** รูปแบบข้อมูลที่หลากหลาย เช่น ตาราง, ภาพ, เสียง
3. **Velocity (ความเร็ว):** ข้อมูลที่ถูกเก็บและประมวลผลอย่างรวดเร็ว
4. **Veracity (ความถูกต้อง):** ข้อมูลที่เชื่อถือได้และสามารถตรวจสอบได้
5. **Value (คุณค่า):** ข้อมูลที่มีประโยชน์ในการตัดสินใจธุรกิจ
6. **Variability (ความแปรผัน):** ข้อมูลที่มีความหลากหลายในการใช้งานและการวิเคราะห์

บทที่ 3

***Business Case Evaluation (BCE)** คือ การประเมินธุรกิจเพื่อเข้าใจวิสัยทัศน์ พันธกิจ เป้าหมาย และกลยุทธ์ของธุรกิจก่อนการวิเคราะห์ข้อมูล เพื่อตัดสินใจในกรณีต่างๆ ของธุรกิจ.

แนวทางในการทำ BCE Define the drivers ->State the problem->Formula alternative->Analyze the alternatives->Recommend and Report

วิเคราะห์ SWOT

Strengths Weaknesses Opportunities Threats (จุดแข็ง จุดอ่อน โอกาส อุปสรรค)

“ข้าวเหนียวมะม่วง”

Strengths รสชาติ วัตถุดิบท้องถิ่น

Weaknesses ฤดูกาล เก็บรักษายาก

Opportunities ขยายเมนูใหม่ ตลาดสุขภาพ

Threats คู่แข่งในตลาดอาหาร ปัญหาการส่งออก

***Data Identification:** การระบุแหล่งที่มาของข้อมูล เช่น ชื่อแหล่งที่มาและประเภทของข้อมูล (เช่น ลักษณะของไฟล์).

***Data Acquisition & Filtering:** ข้อมูลจะถูกรวบรวมจากแหล่งที่มาที่ระบุและทำการกรองข้อมูลที่เสียหายหรือไม่มีความออกไป.

***Data Extraction:** ข้อมูลบางส่วนที่ไม่สอดคล้องกับโซลูชันจะถูกแยกออกและแปลงให้อยู่ในรูปแบบที่เหมาะสมสำหรับการวิเคราะห์.

***Data Validation & Cleansing:** ข้อมูลที่มีความซ้ำซ้อนหรือไม่ถูกต้องจะได้รับการตรวจสอบและแก้ไขเพื่อป้องกันการผิดพลาดในการวิเคราะห์.

Data Validation “การตรวจสอบข้อมูล” เป็นส่วนสำคัญของงานจัดการข้อมูลทั้งการรวบรวมข้อมูล การวิเคราะห์ข้อมูลหรือการเตรียมข้อมูลเพื่อนำเสนอข้อมูล

แนวทางของ Data Validation:

- 1. **ตรวจสอบชนิดข้อมูล:** ตรวจสอบให้ข้อมูลตรงกับประเภทที่ต้องการ เช่น ตัวเลข, ข้อความ.
- 2. **ตรวจสอบช่วงข้อมูล:** ตรวจสอบข้อมูลให้อยู่ในช่วงที่กำหนด เช่น อายุไม่เกิน 120 ปี.
- 3. **ตรวจสอบข้อมูลเอกลักษณ์:** ตรวจสอบข้อมูลไม่ซ้ำกัน เช่น รหัสลูกค้าต้องไม่ซ้ำ.
- 4. **ตรวจสอบความสอดคล้องของข้อมูล:** ตรวจสอบความสัมพันธ์ของข้อมูล เช่น วันที่เริ่มต้นไม่เกินวันที่สิ้นสุด.
- 5. **ตรวจสอบค่าว่าง:** ตรวจสอบว่าไม่มีฟิลด์ใดเป็นค่าว่างหรือ NULL.

Data Aggregation & Representation: การรวบรวมข้อมูลจากหลายแหล่งเพื่อสร้างสรุปที่ใช้ในการวิเคราะห์.

Data Visualization: การแสดงข้อมูลเป็นภาพเพื่อให้เข้าใจง่ายและสื่อสารข้อมูลได้รวดเร็ว.

ลักษณะสำคัญของ Data Visualization ได้แก่: ใช้งานง่าย , เข้าใจได้รวดเร็ว , ยืดหยุ่น , ให้ข้อมูลเชิงลึก

ปัจจัยประสิทธิภาพในการทำ Visualization:

Visual cues/Visual encoding: การแปลงข้อมูลให้แสดงในรูปแบบต่างๆ เช่น รูปร่าง, สี, ขนาด.

Coordinate systems: ระบบพิกัดสำหรับใส่ข้อมูล.

Scale/Data types: ข้อมูลที่ต้องสอดคล้องกับระบบพิกัด.

Context: ต้องระบุบริบทของข้อมูลให้ชัดเจน.

Visual Encoding: Position, Length, Angle, Direction, Shape, Area/Volume, Color: วิธีการแสดงข้อมูลด้วยรูปแบบต่างๆ เช่น ตำแหน่ง, ความยาว, สี ฯลฯ.

Data Types:

Numeric: ข้อมูลเชิงปริมาณ.

Categorical: ข้อมูลเชิงคุณลักษณะ.

Time Series: ข้อมูลตามลำดับเวลา.

ชนิดของ Visualizations:

Temporal (ข้อมูลเชิงเวลา): แสดงข้อมูลที่มีลำดับเวลา เช่น:

Scatter plots: แผนภาพกระจาย

Timelines: เส้นเวลา

Polar area diagrams: แผนภูมิพิกัดขั้ว

Time series sequences: ลำดับข้อมูลตามเวลา

Line graphs: กราฟเส้น

Hierarchical (ข้อมูลลำดับชั้น): ใช้กับข้อมูลที่มีลำดับชั้น เช่น:

Tree diagrams (Tree map): แผนภาพต้นไม้

Ring charts: แผนภูมิวงแหวน

Sunburst diagrams: แผนภาพขั้นเบียร์ส

Network (ข้อมูลเครือข่าย): แสดงข้อมูลในลักษณะของเครือข่ายเชื่อมโยงด้วยลิงค์และโหนด.

Multidimensional (ข้อมูลหลายมิติ): แสดงข้อมูลที่มีหลายมิติ เช่น:

Scatter plots: แผนภาพกระจาย

Pie charts: กราฟวงกลม

Venn diagrams: แผนภาพเวนน์

Stacked bar graphs: กราฟแท่งที่ซ้อนกัน

Histograms: ฮิสโตแกรม

Geospatial (ข้อมูลเชิงพื้นที่): แสดงข้อมูลที่เกี่ยวข้องกับสถานที่ในแผนที่ เช่น:

Flow map: แผนที่การไหล

Density map: แผนที่ความหนาแน่น

Heat map: แผนที่ความร้อน

Cartogram: แผนที่ที่สามารถเปลี่ยนแปลงรูปร่างหรือขนาดได้

คุณค่าของการแสดงภาพข้อมูล (The Value of Visualization):

- 1. **ช่วยให้เข้าใจข้อมูลขนาดใหญ่:** การแสดงภาพทำให้ข้อมูลขนาดใหญ่เข้าใจได้ง่ายขึ้น

- 2. **ทำให้ข้อมูลใช้งานง่าย:** ช่วยให้ผู้ใช้เข้าใจข้อมูลได้เร็วขึ้น

- 3. **เห็นความสัมพันธ์ของข้อมูล:** ทำให้เห็นความเชื่อมโยงระหว่างชุดข้อมูล

- 4. **เปลี่ยนมุมมองหรือพฤติกรรม:** ช่วยในการมองข้อมูลใหม่และสามารถเปลี่ยนการตัดสินใจหรือพฤติกรรมได้

บทที่ 2

ตัวอย่างของ Big Data & Data Analytics:

- 1. **Customer Lifetime Value (CLV):** การคำนวณมูลค่าตลอดชีวิตของลูกค้า เพื่อให้เข้าใจว่าลูกค้าคนใดจะมีมูลค่ามากที่สุด
- 2. **Customer Segmentation:** การแบ่งกลุ่มลูกค้าเพื่อกำหนดการตลาดและการขายให้ตรงตามความต้องการ
- 3. **Up-Sell & Cross-Sell:** การขายสินค้าเพิ่มเติมหรือสินค้าคู่กันเพื่อเพิ่มรายได้จากลูกค้าเดิม
- 4. **Next Best Action:** การใช้ข้อมูลวิเคราะห์เพื่อหาวิธีที่ดีที่สุดในการตอบสนองลูกค้าในแต่ละช่วงเวลา
- 5. **Propensity to Buy:** การทำนายโอกาสที่ลูกค้าจะซื้อสินค้าหรือบริการ
- 6. **Churn Prevention:** การคาดการณ์ลูกค้าที่อาจจะยกเลิกบริการและหาวิธีป้องกัน
- 7. **Fraud Detection:** การตรวจจับพฤติกรรมที่ผิดปกติหรือการโกง
- 8. **Risk Management:** การบริหารความเสี่ยงในการดำเนินธุรกิจ
- 9. **Demand Forecast:** การพยากรณ์ความต้องการในตลาดหรือธุรกิจ
- 10. **Price Optimization:** การปรับราคาสินค้าให้เหมาะสมเพื่อเพิ่มประสิทธิภาพในการขาย
- 11. **Quality Assurance:** การรับประกันคุณภาพของผลิตภัณฑ์หรือบริการ
- 12. **Predictive Maintenance:** การทำนายการซ่อมบำรุงที่จำเป็นก่อนที่จะเกิดปัญหา